

Università degli Studi di Salerno

Dipartimento di Informatica

Corso di Laurea Triennale in Informatica

Caratterizzazione degli embedding di immagini prodotte da differenti modelli generativi

Relatore
Prof. Andrea Francesco Abate

Candidato
Francesco Lamanna
Matricola: 0512117166

Anno Accademico 2025/2026

Indice

Abstract **1**

Introduzione **2**

1 Dataset ed estrazione degli embedding **3**
1.1 Immagini reali e immagini generate artificialmente 3
1.2 Principali famiglie di modelli generativi 4
1.3 Dataset e classi considerate 5
1.4 Rappresentazione tramite embedding 6
1.5 Architettura utilizzata per l'estrazione degli embedding 7
1.5.1 Estrazione delle caratteristiche tramite Vision Transformer 8
1.5.2 Rete siamese e Triplet Loss 8
1.5.3 Ottenimento degli embedding a 256 dimensioni 9

2 Metodologia sperimentale **10**
2.1 Obiettivi del lavoro 10
2.2 Organizzazione generale dell'analisi 11
2.3 Valutazione della separabilità 11
2.4 Analisi della similarità tra generatori 12
2.5 Valutazione tramite approccio supervisionato 13
2.6 Analisi della robustezza 14

3 Analisi della separazione tra generatori **15**
3.1 Metriche esterne 16
3.2 Metriche interne 17
3.3 Discussione dei risultati 18

4 Analisi della centralità dei generatori **19**
4.1 Calcolo dei centroidi 19
4.2 Distanze tra centroidi 19
4.2.1 Distanza euclidea 20
4.2.2 Distanza del coseno 21
4.2.3 Distanza di Mahalanobis 21
4.3 Analisi locale tramite KNN-overlap 22

4.4 Silhouette Score per generatore 23
4.5 Confronto tra i metodi di centralità 23

5 Analisi tramite classificatori e matrici di confusione 25
5.1 Classificatori utilizzati 25
5.2 Prime analisi tramite classificatori 26
5.3 Suddivisione dei dati e random state 28
5.4 Top 5 derivate dalle matrici di confusione 28
5.5 Discussione finale e confronto tra classificatori 29

6 Riduzione del training set tramite DBSCAN 30
6.1 DBSCAN e classificazione dei punti 30
6.2 Applicazione di DBSCAN al training set 31
6.3 Rimozione selettiva dal training set 32
6.4 Effetto della rimozione sui risultati 33

7 Discussione complessiva dei risultati 34
7.1 Separabilità nello spazio degli embedding 34
7.2 Centralità e ricorrenza dei generatori 34
7.3 Coerenza tra analisi non supervisionata e classificatori 35
7.4 Robustezza rispetto alla rimozione selettiva 36
7.5 Limiti dell'approccio e sviluppi futuri 37

Conclusioni 38

Bibliografia 40

A Dettagli implementativi e visualizzazioni aggiuntive 43
A.1 Visualizzazioni complete della rimozione selettiva dal training set 43

B Risultati sperimentali aggiuntivi 46
B.1 Top 5 di confusione nelle diverse configurazioni 46
B.2 Top 5 dopo la rimozione selettiva dei punti 51

Abstract

L'obiettivo di questa tesi è analizzare la separabilità e la robustezza di embedding associati a immagini reali e generate da differenti modelli generativi. Il dataset considerato comprende 20 716 campioni appartenenti a 26 classi, di cui 25 corrispondenti a diversi generatori artificiali e una relativa alle immagini reali. Ogni immagine è rappresentata mediante un embedding a 256 dimensioni ottenuto attraverso un'architettura basata su Vision Transformer e Siamese Neural Network.

L'analisi è stata sviluppata attraverso approcci complementari. La separabilità delle classi è stata valutata mediante clustering e metriche interne ed esterne; la centralità e la similarità tra generatori sono state studiate utilizzando distanze tra centroidi, KNN-overlap e Silhouette Score. È stato inoltre adottato un approccio supervisionato basato su Logistic Regression, Random Forest e Naive Bayes, analizzandone sia le prestazioni sia le matrici di confusione. Infine, DBSCAN è stato applicato al training set per distinguere punti core, border e noise e valutare l'impatto della loro rimozione.

I risultati evidenziano una forte separabilità tra le classi: il confronto tra i cluster ottenuti e le etichette reali produce una Normalized Mutual Information pari a 0,9809 e un Adjusted Rand Score pari a 0,9472. Anche i classificatori supervisionati raggiungono prestazioni molto elevate, con valori di accuracy superiori a 0,996. Le diverse analisi mostrano inoltre una particolare ricorrenza di LaMa e MAT, che emergono frequentemente come generatori centrali o maggiormente coinvolti nelle confusioni. L'analisi di robustezza mostra infine che la rimozione dei punti border e core produce variazioni contenute, mentre l'eliminazione dei punti noise determina un aumento più evidente delle confusioni, suggerendo che anche i campioni più isolati contribuiscano alla capacità discriminativa della rappresentazione.

Introduzione

Negli ultimi anni, i modelli generativi per immagini hanno raggiunto risultati sempre più realistici, rendendo sempre più complesso distinguere immagini reali da immagini generate artificialmente. In questo contesto, risulta interessante analizzare se immagini prodotte da generatori differenti occupino regioni diverse all'interno di uno spazio di rappresentazione e se tali differenze possano essere misurate tramite tecniche di clustering, metriche di separabilità e classificatori supervisionati.

Lo scopo di questa tesi è analizzare un insieme di embedding associati a immagini reali e generate, con l'obiettivo di valutare la separazione tra i diversi generatori, individuare quelli maggiormente rappresentativi e studiare la stabilità dei risultati in seguito alla rimozione selettiva di campioni dal training set.

Il lavoro si articola in diverse fasi. In primo luogo viene descritta la rappresentazione delle immagini tramite embedding e il dataset utilizzato. Successivamente viene analizzata la separazione tra i generatori mediante metriche interne ed esterne di clustering. Viene poi affrontato il problema della centralità dei generatori, utilizzando distanze tra centroidi e metodi basati sulla vicinanza locale. Una parte rilevante del lavoro è dedicata all'utilizzo di classificatori supervisionati e matrici di confusione, al fine di studiare le similarità tra generatori. Infine, DBSCAN viene applicato ai dati di addestramento per classificare i punti come core, border e noise, valutando l'impatto della loro rimozione sul comportamento dei classificatori.

Capitolo 1

Dataset ed estrazione degli embedding

Il punto di partenza di questa tesi è costituito da un insieme di embedding associati a immagini reali e immagini generate artificialmente. Prima di descrivere le analisi effettuate su tali rappresentazioni, è necessario chiarire la natura delle immagini considerate, la struttura del dataset e il processo utilizzato per ottenere gli embedding.

In questo capitolo vengono quindi introdotte le principali famiglie di modelli generativi presenti nel dataset e viene descritta l'organizzazione dei campioni nelle diverse classi. Successivamente, viene approfondito il concetto di embedding e viene illustrata l'architettura basata su una rete neurale siamese utilizzata per estrarre le rappresentazioni analizzate nel resto del lavoro.

Gli embedding utilizzati nel lavoro sono stati forniti già calcolati e costituiscono il punto di partenza delle analisi sperimentali.

1.1 Immagini reali e immagini generate artificialmente

Negli ultimi anni, i modelli generativi per immagini hanno raggiunto un livello di qualità sempre più elevato, arrivando in molti casi a produrre immagini difficilmente distinguibili da quelle reali. Questo rende sempre più complesso, soprattutto per l'occhio umano, riconoscere l'origine di un'immagine e stabilire se essa sia autentica oppure generata artificialmente.

Il problema, tuttavia, non riguarda soltanto la distinzione tra immagini reali e immagini generate. Anche confrontando immagini prodotte da generatori differenti, spesso non è semplice individuare caratteristiche visive che permettano di riconoscere il modello utilizzato. Due immagini possono infatti apparire molto simili pur essendo state prodotte da architetture, procedure di addestramento e metodi generativi differenti.

Ogni generatore può introdurre nelle immagini alcune caratteristiche legate al proprio funzionamento. Queste caratteristiche possono riguardare, ad esempio, la struttura delle texture, la gestione dei dettagli, la ricostruzione dei contorni, la distribuzione dei colori oppure la presenza di particolari artefatti. Tali differenze non sono necessariamente evidenti osservando direttamente le immagini, ma possono emergere analizzando rappresentazioni numeriche ottenute attraverso modelli di estrazione delle caratteristiche.

L'idea alla base di questa tesi parte proprio da questa osservazione. Se le differenze tra generatori non sono sempre riconoscibili a livello visivo, è possibile che esse risultino maggiormente evidenti all'interno di uno spazio vettoriale. In questo senso, ogni generatore potrebbe lasciare una sorta di firma nelle immagini prodotte, legata al modo in cui il modello costruisce o modifica il contenuto visivo.

Per questo motivo, risulta interessante studiare non soltanto se le immagini reali siano distinguibili da quelle generate, ma anche se generatori differenti occupino regioni diverse all'interno dello spazio delle rappresentazioni. Questo permette di affrontare il problema come una classificazione multi-classe, nella quale ogni generatore viene considerato come una classe distinta.

1.2 Principali famiglie di modelli generativi

Il dataset considerato comprende diverse famiglie di modelli generativi:

- **Inpainting/Completion**: LaMa [1], MAT [2], Generative_Inpainting, Palette [3]
- **Diffusion Models e modelli ibridi**: DDPM [4], Latent_Diffusion e Stable_Diffusion [5], GLIDE [6], VQ_Diffusion, Diffusion_GAN, Denoising_Diffusion_GAN [7]
- **GAN classici, progressivi e condizionali**: ProGAN, BigGAN, Projected_GAN, CIPS, Cycle_GAN, Star_GAN [8]
- **Style-based GAN**: StyleGAN1 [9], StyleGAN2, StyleGAN3 [10]
- **Modelli con attenzione o Transformer**: GANformer, Taming_Transformer [11]
- **Semantic/Layout-Guided Generation**: GauGAN [12]
- **Face/Synthetic Face Generation**: Face_Synthetics [13], SFHQ

Le principali caratteristiche di queste famiglie possono essere sintetizzate come segue:

- **Inpainting/Completion**: questa famiglia comprende modelli orientati al completamento di immagini, con l'obiettivo di ricostruire regioni mancanti o mascherate in modo coerente con il contesto circostante.
- **Diffusion Models**: questa famiglia comprende modelli che generano immagini mediante un processo iterativo di rimozione del rumore, trasformando progressivamente una distribuzione casuale in immagini visivamente realistiche.
- **GAN classici, progressivi e condizionali**: questa famiglia include modelli generativi basati sull'interazione tra un generatore e un discriminatore. Alcuni di questi modelli utilizzano strategie di addestramento progressivo, condizionamento o traduzione da un dominio all'altro per migliorare la qualità e il controllo delle immagini generate.

- **Style-based GAN**: questa famiglia comprende modelli derivati dalle GAN, ma caratterizzati da un controllo più forte dello stile dell'immagine generata. In questi modelli, la generazione non dipende soltanto da un rumore iniziale, ma anche da rappresentazioni interne che influenzano aspetti come la struttura, i dettagli e le caratteristiche visive dell'immagine.

- **GAN con attenzione/Transformer**: questa famiglia comprende modelli che mantengono la logica tipica delle GAN, ma introducono meccanismi di attenzione per mettere in relazione parti diverse dell'immagine. Questo permette al modello di considerare non solo dettagli locali, ma anche collegamenti più ampi tra regioni distanti dell'immagine.

- **Transformer/Token-based Models**: questa famiglia comprende modelli che rappresentano l'immagine attraverso elementi discreti o token visivi. L'utilizzo dei Transformer permette di modellare le relazioni tra questi elementi, sfruttando meccanismi di attenzione simili a quelli usati in altri ambiti dell'intelligenza artificiale.

- **Semantic/Layout-Guided Generation**: questa famiglia comprende modelli in cui la generazione dell'immagine è guidata da informazioni strutturali, come mappe semantiche o layout. In questi casi il modello non genera liberamente l'immagine, ma segue una struttura di partenza che indica quali elementi devono comparire e dove devono essere posizionati.

- **Face/Synthetic Face Generation**: questa famiglia comprende modelli e dataset orientati alla generazione di volti sintetici. A differenza di generatori più generali, questi approcci si concentrano su un dominio specifico, caratterizzato da una struttura ricorrente ma complessa: posizione degli occhi, forma del volto, espressione, illuminazione, posa e dettagli locali. La generazione di volti sintetici richiede quindi un controllo accurato sia della coerenza globale del volto sia delle caratteristiche più fini, poiché piccole variazioni possono modificare in modo significativo l'identità percepita o la qualità dell'immagine.

Questa suddivisione evidenzia come i generatori considerati non appartengano a un'unica categoria, ma derivino da approcci diversi alla generazione di immagini. Di conseguenza, è ragionevole aspettarsi che alcuni generatori possano produrre rappresentazioni più simili tra loro, mentre altri possano risultare più facilmente distinguibili.

1.3 Dataset e classi considerate

Le immagini da cui derivano gli embedding analizzati appartengono all'Artifact Dataset, un dataset sviluppato per lo studio e il riconoscimento delle immagini generate artificialmente [14].

Il dataset originale comprende una raccolta eterogenea di immagini reali e generate. Le immagini rappresentano diverse categorie di contenuto, tra cui persone, volti, animali, luoghi,

veicoli, opere artistiche e altri oggetti presenti nel mondo reale. La presenza di contenuti differenti permette di evitare che il riconoscimento delle immagini artificiali dipenda esclusivamente da una singola categoria visiva.

La parte reale del dataset è stata costruita utilizzando immagini provenienti da diverse raccolte di dati. La parte generata comprende invece immagini prodotte da 25 differenti approcci generativi, appartenenti alle famiglie descritte nella sezione precedente. Sono presenti sia generatori che producono completamente l'immagine sia modelli che modificano o ricostruiscono soltanto alcune regioni.

Il dataset complessivamente disponibile per le analisi di questa tesi è costituito da 20 716 campioni. Ogni campione corrisponde a una singola immagine ed è rappresentato mediante un embedding a 256 dimensioni. A ciascun embedding è associata un'etichetta che indica la classe di appartenenza dell'immagine. La distribuzione dei campioni tra le classi è pressoché bilanciata: 25 classi contengono 800 campioni ciascuna, mentre la classe DDPM ne contiene 716.

Nelle analisi di clustering e centralità viene considerato l'intero insieme degli embedding. Nelle analisi supervisionate, invece, i campioni vengono suddivisi in insiemi distinti di training, validation e test, secondo le configurazioni descritte nel Capitolo 5.

Le classi complessive sono 26: 25 classi corrispondono ai differenti generatori artificiali, mentre una classe, indicata come REAL, contiene le immagini reali. Il problema analizzato non è quindi soltanto binario, cioè reale contro generato, ma è un problema multi-classe.

Questa distinzione è importante perché permette di approfondire l'analisi. Limitarsi alla separazione tra immagini reali e immagini artificiali consentirebbe di valutare soltanto se il modello di rappresentazione conserva informazioni generali sulla natura sintetica dell'immagine. Considerando separatamente i 25 generatori, è invece possibile verificare se gli embedding conservino anche informazioni più specifiche sul modello di provenienza.

Il dataset può quindi essere interpretato come una nuvola di 20 716 punti all'interno di uno spazio a 256 dimensioni. Ogni punto rappresenta un'immagine, mentre la sua posizione dipende dai valori che compongono l'embedding. L'etichetta associata al punto permette di collegarlo al generatore di provenienza oppure alla classe delle immagini reali.

Nel lavoro sperimentale non vengono analizzati direttamente i pixel delle immagini. Tutte le operazioni di clustering, calcolo delle distanze, classificazione e riduzione dei dati vengono effettuate utilizzando gli embedding già estratti. Le immagini originali costituiscono quindi la sorgente dei dati, mentre gli embedding rappresentano il vero punto di partenza delle analisi svolte nella tesi.

1.4 Rappresentazione tramite embedding

Un'immagine digitale può essere rappresentata direttamente attraverso i valori dei suoi pixel. Questa rappresentazione contiene tutte le informazioni visive dell'immagine, ma presenta una dimensionalità molto elevata e non è sempre adatta al confronto tra contenuti complessi.

Due immagini che rappresentano un contenuto simile possono infatti avere valori dei pixel molto diversi a causa di variazioni nell'illuminazione, nella posizione degli oggetti, nella

risoluzione o nei colori. Allo stesso modo, piccole differenze nei pixel non corrispondono necessariamente a differenze importanti dal punto di vista del contenuto rappresentato.

Per questo motivo, in molti ambiti vengono utilizzate rappresentazioni più compatte, chiamate embedding. Un embedding è un vettore numerico che cerca di riassumere le caratteristiche principali di un dato, in questo caso di un'immagine [15].

Attraverso l'estrazione delle caratteristiche, ogni immagine viene trasformata in un punto all'interno di uno spazio vettoriale. Immagini che condividono determinate caratteristiche possono essere rappresentate da punti relativamente vicini, mentre immagini differenti possono occupare regioni più distanti.

Questo passaggio permette di applicare strumenti matematici e statistici che sarebbero più difficili da utilizzare direttamente sui pixel. Nello spazio degli embedding è possibile calcolare distanze e similarità, individuare gruppi di punti, misurare la compattezza delle classi e addestrare classificatori supervisionati.

Le singole dimensioni di un embedding non devono necessariamente essere interpretate separatamente. Non è detto, ad esempio, che una determinata componente del vettore corrisponda direttamente a una caratteristica visiva facilmente descrivibile. È il vettore nel suo complesso a rappresentare il contenuto dell'immagine.

La scelta di lavorare con embedding a 256 dimensioni permette di ottenere una rappresentazione di dimensione fissa e molto più compatta rispetto ai pixel originali.

Nel caso delle immagini generate artificialmente, questo approccio è particolarmente interessante. Anche quando due immagini appaiono simili a livello visivo, il processo generativo può lasciare tracce differenti nella loro rappresentazione. Lo spazio degli embedding può quindi rendere osservabili differenze che non risultano immediatamente evidenti attraverso la sola analisi visiva.

1.5 Architettura utilizzata per l'estrazione degli embedding

Gli embedding analizzati nella tesi sono stati ottenuti attraverso un'architettura basata su una Siamese Neural Network, o rete neurale siamese [16].

Le reti siamesi sono architetture progettate per apprendere una misura di similarità tra diversi input. A differenza di un classificatore tradizionale, che assegna direttamente un'immagine a una determinata classe, una rete siamese cerca di costruire uno spazio nel quale immagini considerate simili risultino vicine, mentre immagini differenti risultino più distanti.

L'architettura utilizzata combina un Vision Transformer per l'estrazione iniziale delle caratteristiche con due livelli completamente connessi. Durante l'addestramento, le immagini vengono organizzate in gruppi di tre elementi, chiamati triplette. Le rappresentazioni prodotte vengono quindi confrontate attraverso una funzione di perdita, con l'obiettivo di organizzare lo spazio degli embedding in base alla similarità tra le immagini.

1.5.1 Estrazione delle caratteristiche tramite Vision Transformer

La prima parte dell'architettura è costituita da un Vision Transformer, indicato anche con l'acronimo ViT [17].

Il Vision Transformer elabora un'immagine suddividendola in regioni più piccole, chiamate *patch*. Ciascuna patch viene trasformata in una rappresentazione numerica e trattata come un elemento di una sequenza, in modo simile a quanto avviene nei Transformer utilizzati per l'elaborazione del linguaggio.

Attraverso i meccanismi di attenzione, il modello può mettere in relazione regioni differenti dell'immagine. In questo modo vengono considerate sia le caratteristiche locali, relative alle singole porzioni dell'immagine, sia le relazioni più ampie tra elementi distanti.

Il risultato è una rappresentazione globale dell'immagine, che contiene informazioni sulle sue principali caratteristiche visive. Tale rappresentazione viene successivamente fornita alla parte siamese dell'architettura.

Nel processo utilizzato per ottenere gli embedding, il Vision Transformer viene mantenuto congelato durante l'addestramento. I suoi parametri non vengono quindi modificati. Durante l'addestramento vengono aggiornati soltanto i livelli completamente connessi successivi.

1.5.2 Rete siamese e Triplet Loss

La rappresentazione prodotta dal Vision Transformer viene elaborata attraverso due livelli completamente connessi. Il primo livello riduce la rappresentazione a 512 dimensioni, mentre il secondo produce il vettore finale a 256 dimensioni. Tra i due livelli viene applicata la funzione di attivazione ReLU, che introduce una trasformazione non lineare.

Durante l'addestramento, la rete riceve tre immagini:

- un'immagine *anchor*, utilizzata come riferimento;
- un'immagine *positive*, considerata simile all'anchor;
- un'immagine *negative*, considerata differente dall'anchor.

Nel contesto considerato, l'anchor e il positive appartengono alla stessa categoria generale, mentre il negative appartiene alla categoria opposta. Ad esempio, l'anchor e il positive possono essere due immagini reali, mentre il negative può essere un'immagine generata. La tripletta può essere costruita anche in modo inverso, utilizzando due immagini generate e un'immagine reale.

Le tre immagini vengono elaborate mediante rami identici della rete, che condividono la stessa struttura e gli stessi parametri. Da questa caratteristica deriva il termine "siamese": ciascun ramo applica la stessa trasformazione all'immagine ricevuta.

Per addestrare la rete viene utilizzata la Triplet Loss [18]. Questa funzione ha l'obiettivo di avvicinare nello spazio degli embedding l'anchor e il positive e, allo stesso tempo, allontanare l'anchor dal negative.

In questo modo, la rete apprende progressivamente una rappresentazione nella quale le immagini considerate simili tendono a occupare posizioni vicine, mentre quelle considerate differenti tendono a essere separate.

1.5.3 Ottenimento degli embedding a 256 dimensioni

Le triplette vengono utilizzate durante la fase di addestramento della rete. Una volta completato l'addestramento, ogni immagine può essere elaborata singolarmente attraverso il Vision Transformer e i livelli completamente connessi, ottenendo il relativo embedding.

Il risultato finale è un vettore composto da 256 valori numerici. Ogni embedding mantiene quindi la stessa dimensione e appartiene allo stesso spazio vettoriale, rendendo possibile confrontare direttamente le diverse immagini attraverso misure di distanza o similarità.

A ogni vettore viene associata l'etichetta del generatore che ha prodotto l'immagine oppure l'etichetta REAL, nel caso delle immagini reali. Si ottiene così il dataset multi-classe utilizzato nelle analisi successive.

Capitolo 2

Metodologia sperimentale

Dopo aver descritto il dataset e il procedimento utilizzato per ottenere gli embedding, in questo capitolo viene presentata la metodologia seguita per analizzare tali rappresentazioni.

L'obiettivo generale del lavoro è comprendere se lo spazio degli embedding conservi informazioni relative al generatore di provenienza delle immagini. In particolare, si vuole verificare se immagini prodotte dallo stesso generatore tendano a occupare regioni riconoscibili dello spazio e se generatori differenti presentino relazioni di vicinanza o similarità.

Per affrontare il problema non è stato utilizzato un unico metodo. Il lavoro combina infatti analisi non supervisionate, misure di distanza, classificatori supervisionati ed esperimenti di rimozione selettiva dei punti. Questa scelta permette di osservare gli embedding da prospettive differenti e di verificare se le osservazioni ottenute rimangano coerenti anche cambiando il tipo di analisi.

Il capitolo descrive quindi il procedimento generale seguito, senza anticipare i risultati sperimentali. I dettagli relativi agli algoritmi utilizzati, alle configurazioni considerate e ai valori ottenuti vengono presentati nei capitoli successivi.

2.1 Obiettivi del lavoro

Il punto di partenza della tesi è costituito da embedding associati a immagini reali e a immagini prodotte da differenti modelli generativi. Ogni embedding rappresenta numericamente una singola immagine ed è associato all'etichetta del generatore di provenienza oppure alla classe delle immagini reali.

L'architettura descritta nel capitolo precedente è stata progettata per favorire la distinzione generale tra immagini reali e immagini generate. L'obiettivo di questa tesi è approfondire il comportamento degli embedding, verificando se essi conservino anche informazioni più specifiche relative ai singoli generatori.

L'analisi viene sviluppata considerando tre aspetti principali: la separabilità, la similarità e la robustezza.

La separabilità riguarda la possibilità di distinguere le diverse classi all'interno dello spazio degli embedding. Se i punti appartenenti allo stesso generatore tendono a formare gruppi rico-

noscibili e separati dagli altri, significa che la rappresentazione numerica conserva informazioni utili sull'origine delle immagini.

La similarità riguarda invece le relazioni tra generatori differenti. Anche quando le classi risultano complessivamente separabili, alcuni generatori possono trovarsi più vicini tra loro, risultare meno isolati oppure essere maggiormente coinvolti negli errori dei classificatori.

La robustezza riguarda infine la stabilità delle osservazioni effettuate. L'obiettivo è verificare se i risultati rimangano simili anche modificando la composizione del training set oppure cambiando la suddivisione dei campioni utilizzati durante gli esperimenti.

Il lavoro non cerca quindi di stabilire quale generatore sia migliore o peggiore. L'interesse principale è comprendere come le immagini prodotte dai diversi modelli vengano rappresentate nello spazio degli embedding e quali relazioni emergano tra le classi considerate.

2.2 Organizzazione generale dell'analisi

Il procedimento sperimentale è stato organizzato in diverse fasi, ciascuna dedicata a un aspetto specifico dello spazio degli embedding.

In una prima fase viene analizzata la separazione tra le classi. L'obiettivo è verificare se i punti tendano a organizzarsi in gruppi coerenti con i generatori di provenienza e se la struttura osservata possa essere misurata attraverso opportuni criteri.

Successivamente viene studiata la posizione occupata dai diversi generatori nello spazio vettoriale. Questa fase permette di andare oltre la semplice separazione, cercando di individuare le classi più centrali, quelle maggiormente isolate e quelle che risultano più vicine ad altri generatori.

Una terza fase utilizza un approccio supervisionato. Gli embedding e le relative etichette vengono forniti a diversi classificatori, con l'obiettivo di verificare se il generatore di provenienza possa essere riconosciuto automaticamente.

Gli errori dei classificatori vengono poi analizzati per individuare quali classi siano maggiormente coinvolte nelle confusioni. Questa analisi permette di osservare la similarità tra generatori da un punto di vista differente rispetto alle misure geometriche.

Infine, viene studiata la robustezza dei risultati modificando la composizione del training set. Alcune categorie di punti vengono rimosse separatamente dai dati di addestramento, mentre gli insiemi di validation e test rimangono invariati. Il comportamento dei classificatori viene quindi confrontato con quello osservato utilizzando il training set completo.

L'utilizzo di più fasi permette di verificare se le osservazioni ottenute dipendano da un singolo metodo oppure se emergano in modo ricorrente attraverso approcci differenti.

2.3 Valutazione della separabilità

La prima parte dell'analisi riguarda la separabilità delle classi nello spazio degli embedding.

L'idea di partenza è che, se la rappresentazione conserva informazioni relative al generatore, le immagini prodotte dallo stesso modello dovrebbero risultare più vicine tra loro rispetto alle immagini appartenenti ad altre classi.

Per verificare questa ipotesi viene utilizzato un approccio di clustering. Il clustering permette di suddividere automaticamente i punti in gruppi senza utilizzare direttamente le etichette reali durante la costruzione della partizione.

La suddivisione ottenuta automaticamente viene poi confrontata con quella reale del dataset. In questo modo è possibile osservare se i gruppi individuati attraverso la sola disposizione degli embedding corrispondano alle classi dei diversi generatori.

Accanto al confronto con le etichette reali, viene valutata anche la qualità geometrica dei gruppi. L'obiettivo è osservare quanto i punti appartenenti alla stessa classe risultino compatti e quanto le diverse classi siano separate tra loro.

L'utilizzo congiunto di questi due punti di vista permette di distinguere tra due aspetti differenti. Da una parte si verifica la corrispondenza tra i gruppi individuati e le classi reali, dall'altra si analizza direttamente la struttura dello spazio degli embedding.

Questa prima fase fornisce quindi una valutazione generale della separabilità dei generatori e costituisce il punto di partenza per le analisi successive.

2.4 Analisi della similarità tra generatori

La separabilità complessiva non descrive completamente le relazioni tra le classi. Due generatori possono infatti risultare distinguibili, ma allo stesso tempo essere più vicini tra loro rispetto agli altri.

Per questo motivo, una seconda parte del lavoro è dedicata all'analisi della similarità e della centralità dei generatori.

Una prima prospettiva considera la posizione media occupata da ciascuna classe nello spazio degli embedding. Ogni generatore viene rappresentato attraverso un punto medio, che permette di sintetizzare la distribuzione dei suoi campioni e di confrontarla con quella delle altre classi.

La vicinanza tra generatori viene studiata utilizzando differenti misure di distanza. L'impiego di più misure è motivato dal fatto che ciascuna considera un aspetto diverso della relazione tra i vettori. Alcune osservano maggiormente la distanza geometrica, altre l'orientamento delle rappresentazioni oppure la struttura statistica dei dati.

Per ciascun generatore viene quindi valutata la distanza rispetto alle altre classi. I generatori che risultano mediamente più vicini agli altri possono essere interpretati come maggiormente centrali, mentre quelli più distanti possono essere considerati più isolati.

L'analisi della posizione media viene affiancata da metodi che osservano direttamente la vicinanza tra i singoli punti. Questo permette di considerare anche la distribuzione locale degli embedding e di verificare se campioni appartenenti a classi differenti tendano a comparire nelle stesse regioni dello spazio.

L'utilizzo congiunto di analisi globali e locali consente di ottenere una descrizione più completa delle relazioni tra i generatori. L'obiettivo non è ottenere necessariamente un'unica classifica, ma osservare quali classi emergano in modo ricorrente attraverso metodi differenti.

2.5 Valutazione tramite approccio supervisionato

Dopo aver analizzato la struttura geometrica degli embedding, viene utilizzato anche un approccio supervisionato.

In questo caso, le etichette reali vengono impiegate per addestrare modelli in grado di riconoscere il generatore di provenienza di ciascun campione. L'obiettivo è verificare se le informazioni contenute negli embedding siano sufficienti per distinguere automaticamente le diverse classi.

Sono stati considerati tre classificatori differenti. La scelta di utilizzare più modelli permette di confrontare approcci con caratteristiche diverse e di verificare se le difficoltà di classificazione dipendano da uno specifico algoritmo oppure dalla struttura degli embedding.

Se alcuni generatori vengono confusi in modo simile da classificatori differenti, è possibile che tale comportamento non dipenda soltanto dal modello utilizzato, ma rifletta una reale vicinanza tra le classi nello spazio vettoriale.

Il dataset viene suddiviso in insiemi distinti per l'addestramento e la valutazione dei modelli. Sono state considerate diverse modalità di suddivisione, con l'obiettivo di verificare che le osservazioni ottenute non dipendano esclusivamente da una particolare selezione dei campioni.

La suddivisione dei dati può infatti influenzare i risultati, soprattutto quando il numero di errori è contenuto. Ripetere gli esperimenti con configurazioni differenti permette quindi di valutare la stabilità delle classi maggiormente coinvolte nelle confusioni.

I dettagli relativi ai classificatori, alle suddivisioni utilizzate e alle impostazioni sperimentali vengono descritti nel capitolo dedicato all'analisi supervisionata.

Oltre alla capacità generale di riconoscere le classi, vengono analizzati anche gli errori commessi dai modelli.

Le matrici di confusione permettono infatti di osservare non soltanto quanti campioni siano stati classificati correttamente, ma anche tra quali generatori avvengano gli scambi.

L'interesse principale è individuare le classi che compaiono più frequentemente nelle confusioni. Un generatore spesso coinvolto negli errori può occupare una posizione vicina ad altre classi oppure presentare caratteristiche meno facilmente distinguibili.

Per evitare di riportare integralmente matrici di grandi dimensioni, le confusioni vengono sintetizzate individuando, per ciascun esperimento, i generatori maggiormente coinvolti negli errori.

Le classifiche ottenute vengono confrontate tra i diversi classificatori e tra le differenti suddivisioni del dataset. In questo modo è possibile osservare se alcuni generatori emergano soltanto occasionalmente oppure presentino un comportamento ricorrente.

I risultati dell'approccio supervisionato vengono inoltre confrontati con quelli dell'analisi della centralità. Questo confronto serve a verificare se le classi che risultano più vicine o meno isolate nello spazio degli embedding siano anche quelle che i classificatori tendono a confondere maggiormente.

2.6 Analisi della robustezza

L'ultima parte della metodologia riguarda la robustezza dei risultati rispetto alla rimozione selettiva di alcuni punti.

Non tutti gli embedding occupano la stessa posizione nello spazio. Alcuni si trovano all'interno di regioni particolarmente dense, altri sono collocati ai margini dei gruppi, mentre altri ancora risultano più isolati.

Per distinguere queste diverse categorie viene utilizzato un algoritmo di clustering basato sulla densità. L'obiettivo non è ottenere una nuova suddivisione delle classi, ma classificare i punti in base alla loro posizione rispetto alle regioni più dense dello spazio.

Dopo aver effettuato questa classificazione, vengono costruite diverse versioni del training set. In ogni esperimento viene rimossa una sola categoria di punti, mantenendo inalterate le altre.

Questa scelta permette di osservare separatamente l'effetto delle diverse rimozioni. Eliminare più categorie contemporaneamente renderebbe infatti più difficile comprendere quale tipo di punto abbia determinato le eventuali variazioni.

I classificatori vengono successivamente addestrati sia sul training set completo sia sulle sue versioni ridotte. La valutazione viene effettuata mantenendo invariati gli insiemi di validation e test, in modo che le differenze osservate possano essere attribuite alla modifica dei dati di addestramento.

Se i risultati rimangono simili dopo una determinata rimozione, significa che il comportamento dei classificatori è relativamente stabile rispetto all'eliminazione di quella categoria di campioni. Se invece le confusioni cambiano in modo più evidente, è possibile che i punti rimossi contenessero informazioni importanti per distinguere le classi.

L'analisi non serve quindi soltanto a ridurre il numero di campioni utilizzati durante l'addestramento, ma soprattutto a comprendere il ruolo delle diverse regioni dello spazio degli embedding.

A supporto dell'analisi vengono utilizzate anche rappresentazioni grafiche a dimensionalità ridotta. Queste visualizzazioni permettono di osservare la disposizione dei punti prima e dopo le rimozioni, ma non vengono utilizzate come criterio per formulare le conclusioni.

Nei capitoli successivi vengono presentati nel dettaglio i metodi impiegati nelle diverse fasi, le configurazioni sperimentali considerate e i risultati ottenuti.

Capitolo 3

Analisi della separazione tra generatori

Come descritto nel capitolo precedente, la prima fase dell'analisi riguarda la separabilità delle classi nello spazio degli embedding. In questo capitolo vengono presentati i metodi utilizzati per effettuare tale valutazione e i risultati ottenuti confrontando la struttura individuata automaticamente con le etichette reali del dataset.

Per visualizzare la disposizione generale dello spazio degli embedding, in Figura 3.1 è riportata la proiezione tridimensionale dell'intero dataset ottenuta mediante t-SNE [19].

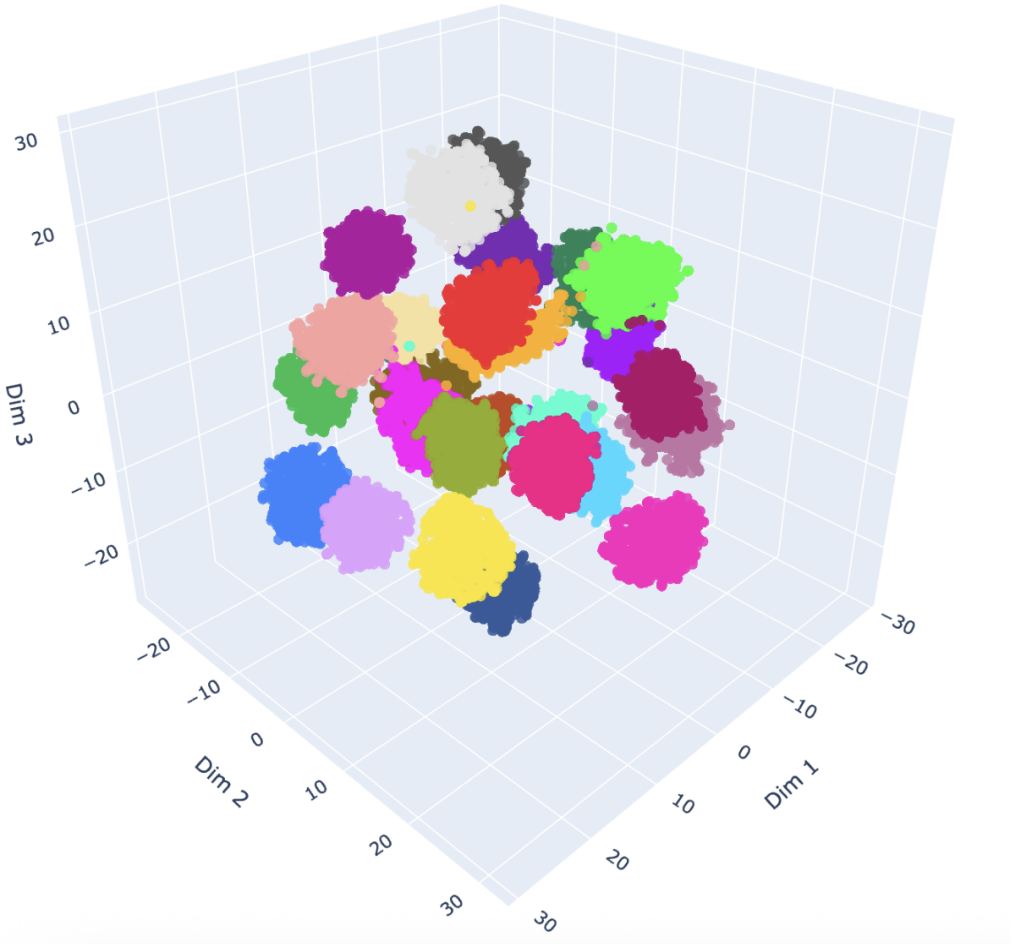


Figura 3.1: Proiezione t-SNE tridimensionale dell'intero dataset di embedding.

3.1 Metriche esterne

Le metriche esterne vengono utilizzate quando sono disponibili le etichette reali dei campioni. Nel caso di questa tesi, ogni embedding possiede un'etichetta che indica il generatore di provenienza oppure la classe delle immagini reali. Questo permette di confrontare una partizione ottenuta automaticamente con la classificazione reale del dataset.

In particolare, è stato applicato K-Means [20] per ottenere una suddivisione automatica dei punti in cluster. Successivamente, i cluster ottenuti sono stati confrontati con le etichette reali mediante due metriche esterne: Normalized Mutual Information [21] e Adjusted Rand Score [22].

La Normalized Mutual Information confronta la suddivisione ottenuta dal clustering con le etichette reali dei generatori. In pratica, permette di capire quanto i cluster trovati automaticamente siano coerenti con le classi reali. Un valore vicino a 1 indica che la partizione prodotta dal clustering è molto simile alla suddivisione reale del dataset.

L'Adjusted Rand Score, invece, misura quanto la partizione ottenuta tramite clustering coincide con le etichette reali, correggendo il risultato rispetto agli accordi che potrebbero

comparire per caso. Anche in questo caso, un valore vicino a 1 indica che i cluster ottenuti riproducono molto bene la struttura reale delle classi.

Nel caso analizzato, i valori ottenuti sono i seguenti:

Metrica esterna	**Valore**
Normalized Mutual Information	0.9809
Adjusted Rand Score	0.9472

Tabella 3.1: Metriche esterne ottenute confrontando i cluster con le etichette reali.

I valori ottenuti sono molto vicini a 1. Questo indica che i cluster individuati automaticamente risultano molto coerenti con le classi reali del dataset. In altre parole, K-Means riesce a trovare una struttura che corrisponde in modo molto forte alla suddivisione reale tra i generatori.

3.2 Metriche interne

Le metriche interne permettono di valutare la qualità della struttura dei dati senza basarsi direttamente sul confronto con le etichette reali. In questo caso, l'obiettivo è misurare quanto i gruppi siano compatti al loro interno e quanto siano separati tra loro nello spazio degli embedding.

Le metriche considerate sono Silhouette Score [23], Davies-Bouldin Index [24] e Calinski-Harabasz Index [25].

Il Silhouette Score misura quanto un punto è vicino ai punti della propria classe rispetto ai punti delle altre classi. Il valore è compreso tra -1 e 1: valori più alti indicano una separazione migliore.

Il Davies-Bouldin Index valuta il rapporto tra compattezza interna dei gruppi e distanza tra gruppi diversi. In questo caso, valori più bassi indicano una qualità migliore della separazione.

Il Calinski-Harabasz Index confronta la dispersione tra i gruppi con la dispersione interna ai gruppi. Valori più alti indicano una separazione migliore tra le classi.

Le metriche interne sono state calcolate in due configurazioni. Nel primo caso sono state applicate alla partizione ottenuta tramite clustering, nel secondo caso sono state applicate considerando direttamente le etichette reali dei generatori. I risultati ottenuti sono riportati nella seguente tabella:

Metrica interna	**Su cluster ottenuti**	**Su etichette reali**
Silhouette Score	0.5070	0.5394
Davies-Bouldin Index	0.8270	0.6664
Calinski-Harabasz Index	6082.66	7173.77

Tabella 3.2: Confronto tra metriche interne calcolate sui cluster ottenuti e sulle etichette reali.

Dai risultati si osserva che le metriche interne risultano migliori quando vengono calcolate sulle etichette reali. In particolare, il Silhouette Score aumenta, il Davies-Bouldin Index diminuisce e il Calinski-Harabasz Index cresce. Questo suggerisce che la suddivisione reale dei generatori descrive una struttura leggermente più compatta e separata rispetto a quella ottenuta automaticamente dal clustering.

3.3 Discussione dei risultati

I risultati ottenuti mostrano che lo spazio degli embedding presenta una buona separazione tra i generatori. Le metriche esterne assumono valori molto elevati, con Normalized Mutual Information pari a circa 0.981 e Adjusted Rand Score pari a circa 0.947. Questo indica che i cluster ottenuti tramite K-Means sono fortemente coerenti con le classi reali del dataset.

Anche le metriche interne confermano una separazione abbastanza buona. Il Silhouette Score, pur non essendo vicino al valore massimo, assume valori positivi e superiori a 0.5, indicando che i punti tendono a essere più vicini alla propria classe rispetto alle altre. Il Davies-Bouldin Index risulta inferiore a 1, suggerendo una buona compattezza interna dei gruppi e una discreta separazione tra classi. Il Calinski-Harabasz Index assume valori elevati, confermando ulteriormente la presenza di una struttura distinguibile nello spazio degli embedding.

Un aspetto interessante è che le metriche interne risultano migliori quando vengono calcolate direttamente sulle etichette reali rispetto ai cluster ottenuti tramite K-Means. Questo suggerisce che la suddivisione reale dei generatori descrive una struttura leggermente più ordinata rispetto a quella individuata automaticamente dal clustering.

Nel complesso, i risultati ottenuti indicano che lo spazio degli embedding presenta una buona separazione tra i generatori considerati. Le metriche esterne mostrano una forte coerenza tra i cluster ottenuti automaticamente e le etichette reali, mentre le metriche interne confermano che le classi risultano abbastanza compatte e separate nello spazio vettoriale.

Capitolo 4

Analisi della centralità dei generatori

Dopo aver valutato la separabilità complessiva delle classi, l'analisi viene approfondita studiando la posizione occupata dai singoli generatori nello spazio degli embedding. In questo capitolo vengono presentati i metodi utilizzati per misurare la centralità e la vicinanza tra le classi, insieme ai risultati ottenuti.

4.1 Calcolo dei centroidi

Per studiare la centralità dei generatori è stato utilizzato il centroide di ciascuna classe. Il centroide rappresenta il punto medio degli embedding appartenenti a uno stesso generatore e viene calcolato facendo la media delle componenti dei vettori appartenenti alla classe considerata.

Nel caso di questa tesi, ogni embedding è un vettore a 256 dimensioni. Di conseguenza, anche il centroide di ciascun generatore è un vettore a 256 dimensioni, ottenuto come media degli embedding associati a quel generatore.

L'utilizzo dei centroidi è una tecnica comune nell'analisi di dati rappresentati come punti in uno spazio vettoriale [26]. Nel caso di questa tesi, il centroide è un punto astratto, perché non corrisponde necessariamente a un'immagine reale presente nel dataset. Esso rappresenta una posizione media della classe nello spazio degli embedding. Questo lo distingue dal medoide, che invece corrisponde a un punto effettivamente presente nel dataset e può essere interpretato come il campione reale più rappresentativo del gruppo.

In questa analisi è stato scelto di utilizzare il centroide perché l'obiettivo era confrontare le classi a livello globale, considerando la posizione media di ciascun generatore. Il centroide permette quindi di sintetizzare ogni classe in un unico punto rappresentativo e di confrontare tra loro i diversi generatori mediante misure di distanza.

4.2 Distanze tra centroidi

Una volta calcolato il centroide di ogni generatore, è stata costruita una matrice delle distanze tra centroidi. La matrice ha dimensione 26×26, poiché nel dataset sono presenti 26 classi complessive, includendo anche la classe delle immagini reali.

Ogni riga e ogni colonna della matrice corrisponde a una classe. Il valore presente in una determinata posizione della matrice rappresenta la distanza tra il centroide della classe associata alla riga e il centroide della classe associata alla colonna.

A partire da questa matrice, per ogni generatore è stata calcolata la distanza media rispetto a tutti gli altri centroidi. L'idea è che un generatore con una distanza media più bassa sia, in media, più vicino agli altri e possa quindi essere considerato più centrale. Al contrario, un generatore con una distanza media più alta può essere interpretato come più distante o più isolato nello spazio degli embedding.

Per calcolare le distanze tra centroidi sono state utilizzate diverse misure, in modo da osservare la centralità da punti di vista differenti: distanza euclidea, distanza del coseno [26] e distanza di Mahalanobis [27].

4.2.1 Distanza euclidea

La distanza euclidea è il primo metodo utilizzato per confrontare i centroidi dei generatori. Essa misura la distanza diretta tra due punti nello spazio vettoriale e può essere interpretata come la distanza geometrica più immediata tra due centroidi.

Applicata agli embedding, la distanza euclidea considera le differenze tra le componenti dei vettori e restituisce un valore che rappresenta quanto due centroidi siano lontani nello spazio a 256 dimensioni. Questo metodo ha il vantaggio di essere semplice e intuitivo, ma tratta tutte le dimensioni nello stesso modo e non tiene conto di eventuali relazioni tra le componenti dell'embedding.

Per ogni generatore è stata calcolata la distanza euclidea media rispetto a tutti gli altri centroidi. I generatori con valore medio più basso sono stati considerati più centrali secondo questa misura.

Posizione	**Generatore**	**Distanza media**
1	LaMa	1.2899
2	Projected_GAN	1.2900
3	MAT	1.3022
4	GauGAN	1.3101
5	Taming_Transformer	1.3182

Tabella 4.1: Top 5 dei generatori più centrali secondo la distanza euclidea.

Dai risultati si osserva che LaMa e Projected_GAN ottengono valori molto vicini tra loro e risultano i generatori più centrali secondo la distanza euclidea. Anche MAT, GauGAN e Taming_Transformer presentano una distanza media contenuta, suggerendo una posizione relativamente vicina al resto dei generatori nello spazio degli embedding.

4.2.2 Distanza del coseno

La distanza del coseno misura la differenza di orientamento tra due vettori. A differenza della distanza euclidea, che considera la distanza diretta tra due punti, la distanza del coseno si concentra maggiormente sulla direzione dei vettori nello spazio.

Questo aspetto è particolarmente utile nel caso degli embedding, perché l'orientamento dei vettori può fornire informazioni importanti sulla similarità tra le rappresentazioni. Due centroidi possono infatti non essere molto vicini in termini euclidei, ma avere comunque una direzione simile nello spazio delle feature.

Anche in questo caso, per ogni generatore è stata calcolata la distanza media rispetto agli altri centroidi. I generatori con valori medi più bassi sono stati considerati più centrali secondo la distanza del coseno.

Posizione	**Generatore**	**Distanza media**
1	Projected_GAN	0.9543
2	LaMa	0.9699
3	GauGAN	0.9865
4	MAT	0.9920
5	GLIDE	1.0029

Tabella 4.2: Top 5 dei generatori più centrali secondo la distanza del coseno.

La classifica ottenuta con la distanza del coseno conferma alcuni risultati già osservati con la distanza euclidea. Projected_GAN e LaMa risultano ancora tra i generatori più centrali, seguiti da GauGAN, MAT e GLIDE. Questo risultato è interessante perché mostra che alcuni generatori rimangono tra i più centrali anche cambiando il modo in cui viene misurata la distanza tra i centroidi.

4.2.3 Distanza di Mahalanobis

La distanza di Mahalanobis rappresenta una misura più avanzata rispetto alla distanza euclidea, perché tiene conto non solo della distanza tra i punti, ma anche della distribuzione dei dati e delle relazioni tra le diverse dimensioni.

Nel caso degli embedding, le 256 componenti del vettore non devono necessariamente essere considerate indipendenti tra loro. Alcune dimensioni possono essere correlate oppure avere scale diverse. La distanza di Mahalanobis tiene conto di questi aspetti attraverso la matrice di covarianza.

Per ogni generatore è stata quindi calcolata la distanza media di Mahalanobis rispetto agli altri centroidi. Anche in questo caso, valori medi più bassi indicano una maggiore centralità.

Posizione	Generatore	Distanza media
1	Latent_Diffusion	4.7892
2	REAL	4.7959
3	GLIDE	4.8922
4	LaMa	4.9036
5	Taming_Transformer	4.9102

Tabella 4.3: Top 5 dei generatori più centrali secondo la distanza di Mahalanobis.

Rispetto alle distanze precedenti, la distanza di Mahalanobis produce una classifica parzialmente diversa. In questo caso risultano più centrali Latent_Diffusion, REAL e GLIDE. La presenza di LaMa anche in questa classifica è però interessante, perché indica che questo generatore mantiene una posizione centrale anche utilizzando una misura che tiene conto della struttura statistica dello spazio degli embedding.

4.3 Analisi locale tramite KNN-overlap

Oltre alle distanze tra centroidi, è stato utilizzato anche un metodo basato sulla vicinanza locale tra punti: il KNN-overlap. A differenza delle misure precedenti, che sintetizzano ogni classe attraverso il proprio centroide, questo approccio considera più direttamente la distribuzione dei punti nello spazio degli embedding.

KNN sta per k-Nearest Neighbors [28], cioè k vicini più prossimi. L'idea alla base del metodo è osservare, per ogni punto, quali siano i punti a esso più vicini nello spazio. Se tra i vicini compaiono spesso punti appartenenti ad altre classi, allora è possibile che vi sia una maggiore vicinanza o sovrapposizione tra generatori diversi.

In questa analisi è stata utilizzata la distanza del coseno come misura di distanza e il valore $k = 10$. Le informazioni sui vicini sono state poi aggregate a livello di classe, in modo da ottenere un'indicazione della vicinanza locale tra generatori.

Nel caso del KNN-overlap, valori più alti indicano una maggiore sovrapposizione locale con altre classi. Per questo motivo, i generatori con valori più alti possono essere interpretati come meno isolati e quindi più centrali dal punto di vista locale.

Posizione	Generatore	Mean KNN-overlap
1	MAT	0.001105
2	LaMa	0.000925
3	Denoising_Diffusion_GAN	0.000675
4	Palette	0.000620
5	StyleGAN3	0.000250

Tabella 4.4: Top 5 dei generatori più centrali secondo il KNN-overlap.

I risultati del KNN-overlap evidenziano soprattutto MAT e LaMa, che presentano i valori più alti di sovrapposizione locale. Questo suggerisce che i punti appartenenti a questi generatori tendono ad avere una maggiore vicinanza con punti appartenenti ad altre classi, risultando quindi meno isolati nello spazio degli embedding.

4.4 Silhouette Score per generatore

Come ulteriore metodo di analisi è stato utilizzato il Silhouette Score calcolato a livello di singolo generatore. Nel capitolo precedente questa metrica è stata utilizzata per valutare la separazione complessiva dei gruppi, in questo caso, invece, viene considerata separatamente per ciascuna classe.

Il Silhouette Score misura quanto un punto sia vicino ai punti della propria classe rispetto ai punti appartenenti alle altre classi. Calcolando il valore medio per ogni generatore, è possibile ottenere un'indicazione di quanto quella specifica classe sia compatta e separata dalle altre.

Nel contesto dell'analisi della centralità, l'interpretazione è leggermente diversa rispetto al capitolo precedente. Un valore alto indica una classe ben separata e quindi più isolata. Un valore più basso, invece, può indicare una maggiore vicinanza rispetto ad altre classi. Per questo motivo, in questa sezione vengono considerati più centrali i generatori con valori medi di Silhouette più bassi.

Posizione	**Generatore**	**Mean Silhouette**
1	MAT	0.6184
2	LaMa	0.6376
3	StyleGAN1	0.6862
4	Denoising_Diffusion_GAN	0.7306
5	Palette	0.7308

Tabella 4.5: Top 5 dei generatori meno isolati secondo il Silhouette Score medio.

Anche in questo caso MAT e LaMa risultano tra i generatori meno isolati. Questo risultato è coerente con quanto osservato tramite KNN-overlap e suggerisce che queste classi occupano una posizione relativamente vicina ad altre classi nello spazio degli embedding.

4.5 Confronto tra i metodi di centralità

I metodi utilizzati non producono esattamente la stessa classifica, perché ciascuno valuta la centralità da un punto di vista diverso. Le distanze tra centroidi forniscono una misura globale della posizione media di ogni classe, mentre KNN-overlap e Silhouette Score osservano maggiormente la vicinanza locale o il grado di isolamento dei generatori.

Per confrontare i risultati, nella tabella seguente vengono riportati i primi cinque generatori individuati da ciascun metodo.

Metodo	**Generatori più centrali**
Euclidea	LaMa, Projected_GAN, MAT, GauGAN, Taming_Transformer
Coseno	Projected_GAN, LaMa, GauGAN, MAT, GLIDE
Mahalanobis	Latent_Diffusion, REAL, GLIDE, LaMa, Taming_Transformer
KNN-overlap	MAT, LaMa, Denoising_Diffusion_GAN, Palette, StyleGAN3
Silhouette Score	MAT, LaMa, StyleGAN1, Denoising_Diffusion_GAN, Palette

Tabella 4.6: Confronto tra i generatori più centrali individuati dai diversi metodi.

Dalla tabella si osserva che i risultati non coincidono perfettamente tra tutti i metodi. Questo è prevedibile, poiché ogni misura considera aspetti diversi dello spazio degli embedding. Tuttavia, alcuni generatori compaiono più volte tra le prime posizioni.

In particolare, LaMa compare nella top 5 di tutti i metodi considerati, mentre MAT compare tra i generatori più centrali secondo distanza euclidea, distanza del coseno, KNN-overlap e Silhouette Score. Questo suggerisce che tali generatori occupano una posizione particolarmente rilevante nello spazio degli embedding, risultando spesso vicini agli altri generatori o comunque meno isolati rispetto ad altre classi.

Altri generatori, come Projected_GAN, GauGAN, GLIDE e Taming_Transformer, risultano centrali solo secondo alcuni metodi. Questo indica che la centralità non è una proprietà unica e assoluta, ma dipende dalla misura utilizzata e dal tipo di relazione che si vuole osservare tra le classi.

Capitolo 5

Analisi tramite classificatori e matrici di confusione

Dopo le analisi geometriche e non supervisionate, la separabilità degli embedding viene valutata anche attraverso un approccio supervisionato. In questo capitolo vengono descritti i classificatori utilizzati, le configurazioni sperimentali considerate e l'analisi delle confusioni tra le diverse classi.

5.1 Classificatori utilizzati

Per l'analisi supervisionata sono stati utilizzati tre classificatori: Logistic Regression, Random Forest e Naive Bayes.

La Logistic Regression è un classificatore lineare [29]. Nonostante il nome, può essere utilizzata anche per problemi di classificazione multi-classe. In questo caso, il modello cerca di separare le classi nello spazio degli embedding mediante superfici decisionali lineari. Si tratta quindi di un metodo semplice, ma utile come primo riferimento.

La Random Forest è un classificatore basato su un insieme di alberi decisionali [30]. Ogni albero viene costruito su una parte dei dati e produce una propria decisione. La classificazione finale viene poi ottenuta combinando le decisioni dei diversi alberi. Questo metodo è generalmente più flessibile rispetto a un classificatore lineare, perché può modellare relazioni più complesse tra le variabili.

Il Naive Bayes è invece un classificatore probabilistico [31]. Esso si basa sul calcolo della probabilità che un campione appartenga a una determinata classe, assumendo in modo semplificato che le caratteristiche siano indipendenti tra loro. Anche se questa ipotesi non è sempre realistica, Naive Bayes è spesso utilizzato come modello di confronto perché è semplice, veloce e permette di osservare il comportamento dei dati da un punto di vista probabilistico.

La Logistic Regression è stata configurata con un numero massimo di 2000 iterazioni, mentre la Random Forest è stata costruita utilizzando 100 alberi. Per il terzo modello è stata utilizzata la variante Gaussian Naive Bayes.

5.2 Prime analisi tramite classificatori

Nella prima configurazione sperimentale, i 20 716 campioni disponibili sono stati suddivisi in training set e test set secondo una proporzione 80/20. In particolare, 16 572 campioni sono stati utilizzati per l'addestramento e 4 144 per il test. La suddivisione è stata effettuata utilizzando il random state 42. Anche per i classificatori è stato utilizzato, quando previsto, il valore 42 come random state. Questa configurazione iniziale è stata usata come primo riferimento per osservare il comportamento dei tre modelli.

Le prestazioni complessive dei classificatori sono state valutate utilizzando Accuracy, Precision, Recall e F1-score. Nel caso di Precision, Recall e F1-score è stata utilizzata la media macro, che calcola il risultato separatamente per ciascuna classe e assegna lo stesso peso a tutte le 26 classi considerate.

Classificatore	**Accuracy**	**Precision**	**Recall**	**F1-score**
Logistic Regression	0.997346	0.997387	0.997356	0.997354
Random Forest	0.997828	0.997854	0.997837	0.997839
Naive Bayes	0.996139	0.996186	0.996154	0.996148

Tabella 5.1: Metriche ottenute dai classificatori sul test set nella configurazione 80/20 con random state 42.

I risultati mostrano prestazioni molto elevate per tutti e tre i classificatori. La Random Forest ottiene i valori migliori per tutte le metriche considerate, seguita dalla Logistic Regression e dal Naive Bayes. Le differenze tra i modelli risultano comunque contenute, poiché Accuracy, Precision, Recall e F1-score sono superiori a 0.996 per tutti e tre i classificatori. Questo conferma che gli embedding contengono informazioni fortemente discriminanti rispetto al generatore di provenienza.

Per riassumere le confusioni tra classi è stato utilizzato il valore MeanConfusion. Questa misura indica quanto una classe risulta mediamente coinvolta negli errori del classificatore all'interno della matrice di confusione.

In particolare, l'attenzione non è posta sulla diagonale principale della matrice, che rappresenta le classificazioni corrette, ma sui valori fuori diagonale, che indicano gli errori commessi per la classe considerata. Un valore più alto di MeanConfusion indica quindi che i campioni appartenenti a quella classe vengono assegnati più frequentemente ad altre classi.

Questa misura non viene quindi utilizzata per valutare l'accuratezza complessiva del classificatore, ma per individuare quali generatori risultano più frequentemente coinvolti negli errori e quindi potenzialmente più simili ad altre classi nello spazio degli embedding.

La tabella seguente mostra i cinque generatori maggiormente coinvolti nelle confusioni della Logistic Regression nella configurazione iniziale.

Posizione	Generatore	MeanConfusion
1	LaMa	0.000920
2	MAT	0.000606
3	REAL	0.000280
4	StyleGAN2	0.000280
5	Stable_Diffusion	0.000268

Tabella 5.2: Top 5 dei generatori più coinvolti nelle confusioni della Logistic Regression.

Nel caso della Logistic Regression, LaMa e MAT risultano i generatori più coinvolti nelle confusioni. Questo risultato è interessante perché questi due generatori erano già emersi come rilevanti nell'analisi della centralità, suggerendo una possibile maggiore vicinanza rispetto ad altre classi nello spazio degli embedding.

La seconda tabella riporta invece i risultati ottenuti con Random Forest.

Posizione	Generatore	MeanConfusion
1	MAT	0.000606
2	LaMa	0.000460
3	StyleGAN2	0.000280
4	Palette	0.000242
5	Denoising_Diffusion_GAN	0.000227

Tabella 5.3: Top 5 dei generatori più coinvolti nelle confusioni della Random Forest.

Anche con Random Forest compaiono nuovamente MAT e LaMa nelle prime posizioni. Questo indica che le confusioni non dipendono soltanto dal classificatore lineare, ma si presentano anche utilizzando un modello diverso e più flessibile.

Infine, la tabella seguente mostra i risultati ottenuti con Naive Bayes.

Posizione	Generatore	MeanConfusion
1	MAT	0.001515
2	LaMa	0.000920
3	REAL	0.000280
4	Stable_Diffusion	0.000268
5	CIPS	0.000000

Tabella 5.4: Top 5 dei generatori più coinvolti nelle confusioni del Naive Bayes.

Nel caso del Naive Bayes, MAT assume il valore più alto di MeanConfusion tra i tre classificatori considerati. Anche LaMa compare nuovamente tra le prime posizioni. La presenza ripetuta di questi generatori suggerisce che alcune classi tendano a essere più difficili da separare, indipendentemente dal classificatore utilizzato.

5.3 Suddivisione dei dati e random state

Dopo la prima analisi, basata sulla suddivisione 80/20 del dataset, è stata considerata anche una configurazione 80/10/10. In questo caso, 16 572 campioni sono stati utilizzati per il training set, 2 072 per il validation set e 2 072 per il test set.

La suddivisione è stata effettuata in modo stratificato, così da preservare nei tre insiemi una distribuzione delle classi simile a quella del dataset complessivo. L'introduzione del validation set permette inoltre di separare la fase di addestramento da quella di validazione e dalla valutazione finale sul test set.

Per confrontare direttamente questa configurazione con quella iniziale, è stato utilizzato il random state 42 sia per la suddivisione dei dati sia per i classificatori che prevedono tale parametro. Le prestazioni ottenute sul test set sono riportate nella seguente tabella:

Classificatore	**Accuracy**	**Precision**	**Recall**	**F1-score**
Logistic Regression	0.996622	0.996670	0.996635	0.996628
Random Forest	0.997587	0.997620	0.997596	0.997593
Naive Bayes	0.996139	0.996195	0.996154	0.996147

Tabella 5.5: Metriche ottenute dai classificatori sul test set nella configurazione 80/10/10 con random state 42.

I risultati della configurazione 80/10/10 risultano molto vicini a quelli ottenuti con la suddivisione 80/20. La Random Forest mantiene i valori migliori per tutte le metriche considerate, mentre le differenze tra i tre classificatori rimangono contenute. La diversa suddivisione del dataset non modifica quindi in modo sostanziale il quadro complessivo delle prestazioni.

Successivamente, sono state effettuate ulteriori prove per verificare la stabilità delle classi maggiormente coinvolte nelle confusioni. La configurazione 80/10/10 è stata quindi ripetuta utilizzando i random state None, 42, 123 e 999 per la suddivisione dei dati, mantenendo invece fisso a 42 il random state del classificatore, quando previsto dal modello.

Nel caso del valore None sono state effettuate quattro esecuzioni, poiché l'assenza di un valore prefissato produce ogni volta una diversa suddivisione casuale dei campioni.

Queste prove aggiuntive non sono state utilizzate per confrontare nuovamente le prestazioni complessive dei classificatori, ma per osservare se gli stessi generatori continuassero a comparire tra le classi maggiormente coinvolte nelle confusioni. Una presenza ricorrente nelle diverse configurazioni può infatti indicare un comportamento più stabile e meno dipendente da una singola suddivisione casuale del dataset.

5.4 Top 5 derivate dalle matrici di confusione

Nel corpo principale del capitolo sono state riportate le top 5 relative alla configurazione iniziale, basata su random state 42 e suddivisione 80/20 del dataset. Le prove aggiuntive, effettuate con suddivisione 80/10/10 e con diversi valori di random state, producono complessivamente 21 top 5.

Per evitare di appesantire il capitolo con molte tabelle simili tra loro, l'elenco completo delle top 5 relative alla suddivisione 80/10/10 è riportato in Appendice B.1. Nel capitolo principale viene invece discussa la tendenza generale emersa dagli esperimenti, con particolare attenzione ai generatori che compaiono più spesso tra le prime posizioni.

5.5 Discussione finale e confronto tra classificatori

Nel complesso, l'approccio supervisionato conferma che gli embedding contengono informazioni utili per distinguere i diversi generatori. I valori di confusione risultano generalmente bassi, ma l'analisi delle top 5 permette comunque di osservare quali classi tendono a comparire più spesso tra quelle maggiormente coinvolte negli errori dei classificatori.

L'aspetto più evidente riguarda LaMa e MAT. Considerando le prove aggiuntive con suddivisione 80/10/10 e limitandosi ai valori di MeanConfusion maggiori di zero, LaMa compare in 18 top 5 su 21, mentre MAT compare in 17 top 5 su 21. Questa ricorrenza suggerisce che tali generatori siano coinvolti nelle confusioni in modo abbastanza stabile, e non soltanto in una singola suddivisione casuale del dataset.

Questo risultato è coerente con quanto osservato nel capitolo precedente. Nell'analisi della centralità, infatti, LaMa e MAT comparivano spesso tra i generatori più centrali o meno isolati nello spazio degli embedding. La loro presenza frequente anche nelle confusioni dei classificatori rafforza quindi l'idea che queste classi occupino una posizione particolare nello spazio vettoriale, risultando più vicine ad altre classi o comunque più difficili da separare in modo netto.

Oltre a LaMa e MAT, emergono con minore continuità anche Denoising_Diffusion_GAN, StyleGAN3, GANformer, StyleGAN1, Cycle_GAN e Palette. Questi generatori compaiono in alcune configurazioni, ma con una frequenza più bassa rispetto ai primi due. Questo indica che esistono confusioni secondarie, ma meno stabili.

I tre classificatori non producono esattamente le stesse classifiche. Logistic Regression e Naive Bayes evidenziano in modo più marcato LaMa e MAT, mentre Random Forest mostra una maggiore variabilità, facendo emergere in alcune configurazioni generatori come Palette, Denoising_Diffusion_GAN e StyleGAN3. Tuttavia, la ricorrenza di alcune classi tra modelli diversi indica che le confusioni osservate non dipendono soltanto dal singolo classificatore, ma riflettono in parte la struttura dello spazio degli embedding.

Si può quindi concludere che l'approccio supervisionato conferma la buona separabilità generale dei generatori. Allo stesso tempo, le confusioni evidenziano il ruolo ricorrente di LaMa e MAT già emerso anche nell'analisi della centralità.

Capitolo 6

Riduzione del training set tramite DBSCAN

L'ultima fase dell'analisi riguarda la robustezza dei risultati rispetto alla rimozione selettiva di alcune categorie di campioni dal training set. In questo capitolo viene descritto il funzionamento di DBSCAN, la configurazione utilizzata per classificare gli embedding del training set e i risultati ottenuti dopo le diverse rimozioni.

6.1 DBSCAN e classificazione dei punti

DBSCAN, acronimo di Density-Based Spatial Clustering of Applications with Noise, è un algoritmo di clustering basato sulla densità dei punti [32]. A differenza di altri algoritmi, come K-Means, DBSCAN non richiede di specificare in anticipo il numero di cluster. L'idea principale è individuare regioni dello spazio in cui i punti sono sufficientemente vicini tra loro, separandole dalle zone meno dense.

Nel contesto di questa tesi, DBSCAN è stato utilizzato soprattutto per assegnare ogni punto a una delle seguenti categorie: core, border oppure noise.

I punti core sono punti che si trovano in una zona sufficientemente densa dello spazio. In altre parole, intorno a un punto core è presente un numero adeguato di altri punti vicini. Questi punti possono essere interpretati come elementi più interni o più rappresentativi delle regioni dense degli embedding.

I punti border sono punti che non hanno abbastanza vicini per essere considerati core, ma si trovano comunque vicino a una regione densa. Possono quindi essere interpretati come punti intermedi, collocati ai margini delle zone più compatte.

I punti noise, infine, sono punti che non appartengono chiaramente a una regione densa. Si tratta di punti più isolati, che DBSCAN non riesce ad associare direttamente a un gruppo sufficientemente compatto.

Il comportamento di DBSCAN dipende principalmente da due parametri:
eps e min_samples. Il parametro eps definisce il raggio entro cui cercare i punti vicini. Il parametro min_samples, invece, indica il numero minimo di punti che devono trovarsi entro tale raggio affinché un punto possa essere considerato core.

Nel caso analizzato, DBSCAN è stato utilizzato non tanto per ottenere una nuova suddivisione in cluster, quanto per distinguere i punti in base al loro ruolo nello spazio degli embedding. Questa distinzione viene poi utilizzata per effettuare esperimenti di rimozione selettiva.

6.2 Applicazione di DBSCAN al training set

DBSCAN è stato applicato ai 16 572 embedding appartenenti al training set della configurazione 80/10/10. In una prima modalità, tutti i punti del training set sono stati considerati contemporaneamente. In una seconda modalità, invece, l'algoritmo è stato applicato separatamente ai punti appartenenti a ciascuna classe.

Il confronto tra le due modalità ha mostrato risultati molto simili nella classificazione dei punti. Per questo motivo, nelle analisi successive è stata utilizzata l'applicazione globale di DBSCAN sull'intero training set. Questa scelta permette di mantenere una procedura unica per tutti i generatori e di osservare la struttura complessiva dei dati utilizzati durante l'addestramento.

Prima di fissare i parametri finali di DBSCAN sono state effettuate diverse prove variando i valori di eps e min_samples. L'obiettivo non era ottenere una nuova suddivisione ottimale dei generatori, ma individuare una configurazione utile per distinguere i punti in categorie interpretabili e confrontabili tra loro.

La configurazione scelta è stata eps = 0.22 e min_samples = 15. Questa scelta ha prodotto la seguente suddivisione dei punti:

Categoria	**Numero di punti**
Noise	6353
Border	4955
Core	5264

Tabella 6.1: Suddivisione dei 16 572 punti del training set ottenuta tramite DBSCAN con `min_samples` = 15 ed `eps` = 0.22.

I conteggi riportati si riferiscono esclusivamente ai campioni del training set. Gli insiemi di validation e test non sono stati utilizzati durante l'applicazione di DBSCAN e sono rimasti invariati nei successivi confronti.

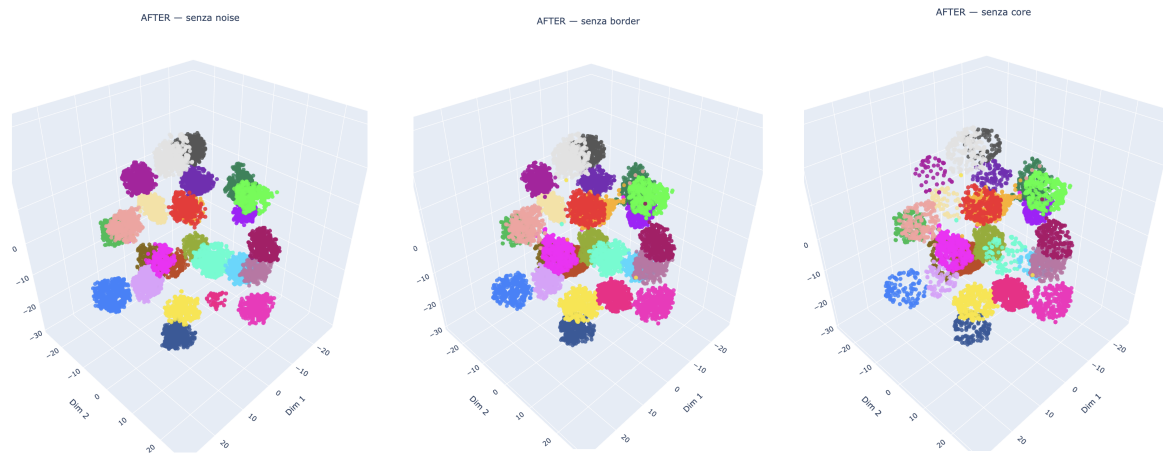
La distribuzione ottenuta non è perfettamente uniforme, ma risulta abbastanza equilibrata da permettere un confronto significativo tra le diverse rimozioni. Una configurazione troppo sbilanciata, con quasi tutti i punti concentrati in una sola categoria, avrebbe reso meno informativa l'analisi successiva. In questo caso, invece, ciascuna categoria contiene un numero consistente di punti del training set, permettendo di valutare separatamente l'effetto della rimozione di noise, border e core.

6.3 Rimozione selettiva dal training set

Dopo aver classificato i punti tramite DBSCAN, sono state costruite tre versioni ridotte del training set, eliminando separatamente i punti noise, border e core. Non sono state considerate rimozioni combinate, così da poter attribuire le eventuali variazioni osservate a una singola categoria di punti.

Per fornire un supporto visivo all'analisi di rimozione selettiva, in Figura 6.1 sono riportate le proiezioni t-SNE tridimensionali del training set dopo la rimozione, rispettivamente, dei punti noise, border e core. Le visualizzazioni complete con il confronto prima/dopo sono riportate in Appendice A.

Le proiezioni t-SNE sono utilizzate esclusivamente a scopo visuale, poiché permettono di rappresentare in tre dimensioni embedding originariamente definiti in uno spazio a 256 dimensioni.



(a) Senza noise (b) Senza border (c) Senza core

Figura 6.1: Proiezioni t-SNE tridimensionali del training set dopo la rimozione selettiva delle categorie individuate tramite DBSCAN.

Le visualizzazioni hanno lo scopo di mostrare la distribuzione dei punti dopo le diverse rimozioni. L'interpretazione principale rimane comunque basata sui risultati ottenuti tramite i classificatori e le matrici di confusione.

In ciascun esperimento, la categoria individuata tramite DBSCAN è stata rimossa esclusivamente dal training set. Ogni classificatore è stato quindi nuovamente addestrato sui campioni rimasti e valutato sugli stessi insiemi di validation e test utilizzati nella configurazione completa. In questo modo, le differenze osservate possono essere attribuite alla modifica dei dati di addestramento, mantenendo invariati i campioni utilizzati per la valutazione.

Per mantenere gli esperimenti confrontabili, i test sono stati effettuati utilizzando il random state 42 sia nella suddivisione del dataset sia nei classificatori in cui questo parametro è disponibile.

Il confronto è stato effettuato partendo dalla configurazione con suddivisione 80/10/10. Per ciascun classificatore sono state confrontate le top 5 ottenute addestrando il modello sul training set completo con quelle ottenute dopo la rimozione dei punti noise, border e core.

6.4 Effetto della rimozione sui risultati

L'effetto della rimozione selettiva è stato valutato confrontando le top 5 dei generatori più coinvolti nelle confusioni ottenute sullo stesso test set, dopo aver addestrato i classificatori sul training set completo oppure sulle sue versioni ridotte. In questo modo è possibile osservare se la rimozione dal training set di noise, border o core produca un peggioramento, un miglioramento oppure una variazione contenuta delle confusioni.

Dai risultati emerge che la rimozione dei punti noise è quella che produce l'effetto più evidente. In tutti e tre i classificatori, infatti, dopo la rimozione dei noise si osserva un aumento dei valori di MeanConfusion per i generatori più coinvolti. Nel caso della Logistic Regression, LaMa passa da 0.0015 a 0.0035 e MAT da 0.0005 a 0.002. Anche con Random Forest, LaMa e MAT raggiungono entrambi 0.0025, mentre con Naive Bayes LaMa arriva a 0.003 e MAT a 0.0015.

Questo risultato è interessante perché mostra che i punti noise non possono essere considerati semplicemente come punti poco utili o eliminabili senza conseguenze. Anche se DBSCAN li identifica come punti più isolati rispetto alle regioni dense, essi sembrano contribuire alla stabilità della classificazione. La loro rimozione, infatti, tende ad aumentare le confusioni dei classificatori.

La rimozione dei punti border produce invece variazioni più contenute. In diversi casi le top 5 rimangono molto simili a quelle ottenute utilizzando il training set completo, sia per i generatori coinvolti sia per i valori di MeanConfusion. Questo suggerisce che i punti di bordo, pur trovandosi in zone intermedie dello spazio degli embedding, non determinano da soli un cambiamento marcato nel comportamento dei classificatori.

Anche la rimozione dei punti core produce effetti generalmente limitati. In alcuni casi si osservano piccole variazioni nei valori o nell'ordine dei generatori presenti nelle top 5, ma senza un aumento evidente come quello osservato dopo la rimozione dei noise. Questo indica che, almeno nella configurazione sperimentale considerata, i classificatori mantengono una buona capacità di riconoscere le classi anche quando dal training set vengono rimossi i punti più interni alle regioni dense.

Un risultato ricorrente riguarda LaMa e MAT, che continuano a comparire frequentemente tra i generatori più coinvolti nelle confusioni anche dopo le diverse rimozioni. Questo è coerente con quanto osservato nei capitoli precedenti: entrambi i generatori erano già emersi come centrali nello spazio degli embedding e come frequentemente presenti nelle top 5 delle confusioni.

Nel complesso, i classificatori mostrano una certa robustezza rispetto alla rimozione selettiva di campioni dal training set, soprattutto nel caso dell'eliminazione dei punti border e core. La rimozione dei noise produce invece un aumento più evidente delle confusioni, suggerendo che anche i campioni di addestramento più isolati contengano informazioni utili per distinguere le classi.

Le tabelle complete relative agli esperimenti di rimozione selettiva sono riportate in Appendice B.2, in modo da mantenere il capitolo principale concentrato sull'interpretazione dei risultati.

Capitolo 7

Discussione complessiva dei risultati

7.1 Separabilità nello spazio degli embedding

I risultati ottenuti nei capitoli precedenti mostrano che lo spazio degli embedding contiene una struttura riconoscibile legata ai generatori di provenienza delle immagini. Questo aspetto emerge in modo evidente già dall'analisi della separazione tra classi, in cui i cluster ottenuti automaticamente risultano fortemente coerenti con le etichette reali del dataset.

Le metriche esterne confermano questa osservazione. La Normalized Mutual Information assume un valore pari a 0.9809, mentre l'Adjusted Rand Score raggiunge 0.9472. Entrambi i valori sono molto vicini a 1 e indicano che la suddivisione individuata tramite clustering è molto simile alla suddivisione reale tra i generatori. Questo suggerisce che gli embedding non rappresentano le immagini in modo casuale, ma conservano informazioni utili a distinguere le classi considerate.

Anche le metriche interne confermano una buona organizzazione dello spazio. Il Silhouette Score risulta positivo e superiore a 0.5, mentre il Davies-Bouldin Index assume valori inferiori a 1. Il Calinski-Harabasz Index, inoltre, presenta valori elevati. Nel complesso, questi risultati indicano che le classi tendono a formare gruppi abbastanza compatti e separati.

Un aspetto rilevante è che le metriche interne risultano migliori quando vengono calcolate sulle etichette reali rispetto ai cluster ottenuti automaticamente. Questo indica che la suddivisione reale dei generatori descrive una struttura leggermente più ordinata rispetto a quella prodotta dal clustering. In altre parole, i generatori sembrano effettivamente lasciare tracce distinguibili nello spazio degli embedding.

7.2 Centralità e ricorrenza dei generatori

L'analisi della centralità ha permesso di osservare non solo se le classi siano separabili, ma anche quali generatori occupino una posizione più vicina alle altre classi. Questo passaggio è importante perché una buona separazione complessiva non esclude la presenza di generatori più centrali, meno isolati o più simili ad altri.

I diversi metodi utilizzati non producono classifiche identiche, poiché ciascuno misura la centralità da un punto di vista differente. Le distanze tra centroidi descrivono una rela-

zione globale tra le classi, mentre KNN-overlap e Silhouette Score per generatore osservano maggiormente la vicinanza locale e il grado di isolamento dei punti.

Nonostante queste differenze, alcuni generatori compaiono più volte tra quelli più centrali. In particolare, LaMa compare nella top 5 di tutti i metodi considerati, mentre MAT compare tra i generatori più centrali secondo distanza euclidea, distanza del coseno, KNN-overlap e Silhouette Score. Questo risultato suggerisce che tali classi occupano una posizione particolarmente rilevante nello spazio degli embedding.

La presenza ricorrente di LaMa e MAT indica che questi generatori non sono semplicemente separabili o non separabili in senso assoluto, ma tendono a collocarsi in regioni meno isolate rispetto ad altre classi. Questo può rendere più probabile la loro vicinanza con generatori differenti e, di conseguenza, può contribuire a spiegare la loro presenza frequente anche nelle confusioni dei classificatori.

Un aspetto da considerare è che LaMa e MAT appartengono entrambi alla famiglia Inpainting/Completion. Questi modelli sono progettati per completare o ricostruire regioni mancanti di un'immagine a partire dal contesto circostante. Di conseguenza, le immagini associate a tali generatori possono mantenere una forte componente strutturale legata all'immagine di partenza, mentre la parte generata riguarda specifiche regioni.

Tuttavia, questa osservazione non è sufficiente da sola a spiegare completamente i risultati. Anche altri generatori considerati nella tesi appartengono alla stessa famiglia, come Generative_Inpainting e Palette. Palette compare in alcune analisi di centralità, in particolare nel KNN-overlap e nel Silhouette Score per generatore, e compare anche in alcune configurazioni delle confusioni. Generative_Inpainting emerge invece soprattutto in alcune configurazioni degli esperimenti di rimozione selettiva e in alcune prove supervisionate, ma non mostra la stessa continuità di LaMa e MAT nelle analisi principali.

Questo suggerisce che la famiglia di appartenenza può fornire una possibile chiave interpretativa, ma non determina automaticamente il comportamento osservato nello spazio degli embedding. La ricorrenza di LaMa e MAT sembra quindi dipendere non solo dal fatto che siano modelli di inpainting, ma anche dalle caratteristiche specifiche dei singoli generatori e dal modo in cui le immagini prodotte vengono rappresentate dagli embedding.

7.3 Coerenza tra analisi non supervisionata e classificatori

L'approccio supervisionato ha permesso di verificare da un altro punto di vista le osservazioni emerse nelle analisi precedenti. I classificatori utilizzati, cioè Logistic Regression, Random Forest e Naive Bayes, confermano che gli embedding contengono informazioni utili per riconoscere il generatore di provenienza delle immagini.

L'analisi delle matrici di confusione non è stata utilizzata soltanto per misurare gli errori, ma soprattutto per individuare quali classi risultano più frequentemente coinvolte nelle confusioni. Questo consente di passare da una valutazione puramente prestazionale a una lettura più interpretativa del comportamento dei classificatori.

Il risultato più evidente riguarda ancora una volta LaMa e MAT. Nelle prove aggiuntive con suddivisione 80/10/10, LaMa e MAT compaiono rispettivamente in 18 e 17 top 5 su 21,

considerando solo valori di MeanConfusion maggiori di zero. Questa ricorrenza suggerisce che il loro coinvolgimento nelle confusioni non dipende soltanto da una singola suddivisione casuale del dataset o da un singolo classificatore.

Questo aspetto è coerente con l'analisi della centralità. I generatori che risultano più centrali o meno isolati nello spazio degli embedding sono anche quelli che compaiono più spesso tra le classi maggiormente coinvolte nelle confusioni. In particolare, LaMa e MAT rappresentano il collegamento più forte tra i risultati geometrici e quelli supervisionati.

La Random Forest mostra una maggiore variabilità, facendo emergere in alcune configurazioni generatori come Palette, Denoising_Diffusion_GAN e StyleGAN3. Logistic Regression e Naive Bayes evidenziano invece in modo più marcato LaMa e MAT. Tuttavia, la presenza ricorrente di alcune classi tra modelli diversi indica che le confusioni osservate riflettono almeno in parte la struttura dello spazio degli embedding, e non soltanto le caratteristiche specifiche del singolo classificatore.

7.4 Robustezza rispetto alla rimozione selettiva

L'ultima parte dell'analisi ha riguardato la robustezza dei risultati rispetto alla rimozione selettiva di campioni dal training set. Tramite DBSCAN, i 16 572 punti utilizzati per l'addestramento sono stati suddivisi in tre categorie: noise, border e core. Successivamente, sono stati effettuati esperimenti rimuovendo una sola categoria alla volta.

Gli insiemi di validation e test sono rimasti invariati durante tutti gli esperimenti. I classificatori sono stati quindi nuovamente addestrati sulle diverse versioni del training set e valutati sugli stessi campioni. Questa impostazione permette di attribuire le variazioni osservate alla modifica dei dati di addestramento.

I risultati mostrano che la rimozione dei punti border e core produce variazioni generalmente contenute. In diversi casi, le top 5 dei generatori più coinvolti nelle confusioni rimangono simili a quelle ottenute utilizzando il training set completo. Questo suggerisce che il comportamento dei classificatori non dipende esclusivamente da una singola categoria di campioni e rimane abbastanza stabile anche dopo una riduzione consistente dei dati di addestramento.

La rimozione dei punti noise produce invece l'effetto più evidente. Dopo l'eliminazione di questi campioni, i valori di MeanConfusion aumentano in tutti e tre i classificatori, soprattutto per LaMa e MAT. Questo risultato mostra che i punti noise non devono essere interpretati automaticamente come elementi inutili o trascurabili.

Anche se DBSCAN identifica i punti noise come più isolati rispetto alle regioni dense, essi sembrano contribuire alla stabilità della classificazione. La loro rimozione dal training set rende più evidenti alcune confusioni, suggerendo che anche le regioni periferiche dello spazio degli embedding contengano informazioni utili durante l'addestramento.

Nel complesso, l'analisi conferma una buona robustezza della procedura di classificazione rispetto alla riduzione del training set, ma mostra anche che alcune categorie di campioni svolgono un ruolo più importante di quanto ci si potrebbe aspettare. In particolare, i punti noise sembrano avere una funzione non trascurabile nell'apprendimento della separazione tra le classi.

7.5 Limiti dell'approccio e sviluppi futuri

Nonostante i risultati ottenuti siano coerenti tra loro, è importante evidenziare alcuni limiti dell'approccio seguito. Un primo limite riguarda la dipendenza dagli embedding utilizzati. Tutte le analisi sono state effettuate su una specifica rappresentazione vettoriale delle immagini, di conseguenza, risultati diversi potrebbero emergere utilizzando un altro modello di estrazione delle feature o embedding di dimensione differente.

Un secondo limite riguarda la composizione del dataset. Le classi considerate comprendono diversi generatori e immagini reali, ma i risultati dipendono comunque dai dati disponibili, dal numero di campioni e dalla distribuzione delle classi. Un dataset più ampio o costruito con generatori differenti potrebbe modificare parzialmente le relazioni osservate nello spazio degli embedding.

Un ulteriore limite riguarda l'interpretazione delle metriche. Le misure utilizzate, come distanze tra centroidi, KNN-overlap, Silhouette Score e matrici di confusione, forniscono prospettive diverse sullo stesso problema, ma non esauriscono completamente la complessità delle relazioni tra generatori. Per questo motivo, i risultati devono essere interpretati come indicatori quantitativi e non come una descrizione assoluta della similarità tra modelli generativi.

Anche la scelta dei parametri di DBSCAN rappresenta un aspetto da considerare. Nel lavoro è stata scelta una configurazione che produce una distribuzione abbastanza equilibrata tra punti noise, border e core. Tuttavia, valori differenti di eps e min_samples potrebbero portare a una diversa suddivisione dei punti e quindi a risultati differenti negli esperimenti di rimozione.

Come sviluppo futuro, sarebbe interessante ripetere l'analisi utilizzando embedding estratti con modelli diversi, in modo da verificare se la ricorrenza di generatori come MAT e LaMa rimanga stabile anche cambiando rappresentazione. Un'altra possibile estensione riguarda l'utilizzo di ulteriori classificatori o metodi di visualizzazione, così da osservare più chiaramente la disposizione delle classi nello spazio.

Conclusioni

L'analisi svolta in questa tesi mostra che gli embedding non rappresentano soltanto una forma compatta e numerica delle immagini, ma possono conservare informazioni significative sull'origine dei dati. Anche quando immagini generate da modelli differenti possono apparire visivamente simili, la loro rappresentazione nello spazio degli embedding permette di osservare strutture, vicinanze e differenze non immediatamente evidenti a livello percettivo.

Il risultato principale del lavoro è che i generatori considerati non si distribuiscono in modo casuale nello spazio vettoriale. Al contrario, le analisi effettuate mostrano una buona separabilità complessiva tra le classi, confermata sia dalle metriche di clustering sia dal comportamento dei classificatori supervisionati. Questo suggerisce che gli embedding utilizzati contengono una traccia dell'identità del generatore, rendendo possibile distinguere non solo immagini reali e immagini artificiali, ma anche immagini prodotte da modelli generativi differenti.

Allo stesso tempo, la tesi evidenzia che la separabilità non deve essere interpretata come una divisione perfetta e uniforme tra tutte le classi. Alcuni generatori risultano più vicini agli altri, più centrali oppure più frequentemente coinvolti nelle confusioni. In particolare, LaMa e MAT emergono in modo ricorrente in analisi diverse, mostrando che alcune classi possono occupare regioni dello spazio meno isolate e quindi più difficili da separare nettamente. Questo rappresenta uno degli aspetti più interessanti del lavoro: non basta chiedersi se i generatori siano distinguibili, ma è utile osservare anche quali generatori tendono ad assomigliarsi maggiormente.

Un ulteriore elemento emerso riguarda il ruolo dei campioni utilizzati durante l'addestramento. L'analisi tramite DBSCAN mostra che non tutte le regioni del training set contribuiscono allo stesso modo alla stabilità dei risultati. In particolare, la rimozione dei punti classificati come noise non produce un semplice miglioramento dovuto all'eliminazione di elementi isolati, ma tende anzi ad aumentare alcune confusioni. Questo suggerisce che anche i campioni di addestramento più periferici possano contenere informazioni utili per distinguere le classi.

Nel complesso, il lavoro conferma l'utilità di analizzare le immagini generate non soltanto dal punto di vista visivo, ma anche attraverso le loro rappresentazioni numeriche. Lo spazio degli embedding permette infatti di studiare i generatori in termini geometrici, statistici e supervisionati, offrendo una prospettiva più ricca rispetto alla sola osservazione delle immagini.

Naturalmente, i risultati ottenuti dipendono dagli embedding utilizzati, dal dataset con-

siderato e dalle metriche scelte. Per questo motivo, le conclusioni non devono essere interpretate come una caratterizzazione assoluta dei generatori analizzati, ma come una valutazione sperimentale del loro comportamento all'interno dello spazio di rappresentazione considerato.

In conclusione, questa tesi mostra che gli embedding possono essere utilizzati come strumento efficace per studiare la separabilità, la similarità e la robustezza delle immagini generate artificialmente. Il contributo principale non consiste soltanto nel verificare che i generatori siano distinguibili, ma nel mostrare che le relazioni tra essi possono essere analizzate in modo più profondo, individuando classi centrali, confusioni ricorrenti e punti particolarmente rilevanti per la stabilità della rappresentazione.

Bibliografia

[1] R. Suvorov, E. Logacheva, A. Mashikhin, A. Remizova, A. Ashukha, A. Silvestrov, N. Kong, H. Goka, K. Park, and V. Lempitsky, *Resolution-Robust Large Mask Inpainting with Fourier Convolutions*, Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2022.

[2] W. Li, Z. Lin, K. Zhou, L. Qi, Y. Wang, and J. Jia, *MAT: Mask-Aware Transformer for Large Hole Image Inpainting*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[3] C. Saharia, W. Chan, H. Chang, C. A. Lee, J. Ho, T. Salimans, D. J. Fleet, and M. Norouzi, *Palette: Image-to-Image Diffusion Models*, ACM SIGGRAPH Conference Proceedings, 2022.

[4] J. Ho, A. Jain, and P. Abbeel, *Denoising Diffusion Probabilistic Models*, Advances in Neural Information Processing Systems, 2020.

[5] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, *High-Resolution Image Synthesis with Latent Diffusion Models*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022.

[6] A. Nichol, P. Dhariwal, A. Ramesh, P. Shyam, P. Mishkin, B. McGrew, I. Sutskever, and M. Chen, *GLIDE: Towards Photorealistic Image Generation and Editing with Text-Guided Diffusion Models*, arXiv preprint arXiv:2112.10741, 2021.

[7] Z. Xiao, K. Kreis, and A. Vahdat, *Tackling the Generative Learning Trilemma with Denoising Diffusion GANs*, International Conference on Learning Representations, 2022.

[8] I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, *Generative Adversarial Nets*, Advances in Neural Information Processing Systems, 2014.

[9] T. Karras, S. Laine, and T. Aila, *A Style-Based Generator Architecture for Generative Adversarial Networks*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.

[10] T. Karras, M. Aittala, S. Laine, E. Härkönen, J. Hellsten, J. Lehtinen, and T. Aila, *Alias-Free Generative Adversarial Networks*, Advances in Neural Information Processing Systems, 2021.

[11] P. Esser, R. Rombach, and B. Ommer, *Taming Transformers for High-Resolution Image Synthesis*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021.

[12] T. Park, M.-Y. Liu, T.-C. Wang, and J.-Y. Zhu, *Semantic Image Synthesis with Spatially-Adaptive Normalization*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019.

[13] E. Wood, T. Baltrusaitis, C. Hewitt, S. Dziadzio, M. Johnson, V. Estellers, T. J. Cashman, and J. Shotton, *Fake It Till You Make It: Face Analysis in the Wild Using Synthetic Data Alone*, Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021.

[14] M. A. Rahman, B. Paul, N. H. Sarker, Z. I. A. Hakim and S. A. Fattah, *Artifact: A Large-Scale Dataset with Artificial and Factual Images for Generalizable and Robust Synthetic Image Detection*, Proceedings of the IEEE International Conference on Image Processing, pp. 2200–2204, 2023.

[15] Y. Bengio, A. Courville, and P. Vincent, *Representation Learning: A Review and New Perspectives*, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. 35, no. 8, pp. 1798–1828, 2013.

[16] A. Castiglione, L. Cimmino, M. Nappi, M. Polsinelli and C. Sorrentino, *Robust Fake Image Detection via Incremental Training of Siamese Neural Networks*, in Lecture Notes in Computer Science, vol. 16195, pp. 332–345, Springer, 2026.

[17] A. Dosovitskiy et al., *An Image is Worth 16 × 16 Words: Transformers for Image Recognition at Scale*, International Conference on Learning Representations, 2021.

[18] F. Schroff, D. Kalenichenko, and J. Philbin, *FaceNet: A Unified Embedding for Face Recognition and Clustering*, Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pp. 815–823, 2015.

[19] L. van der Maaten and G. Hinton, *Visualizing Data using t-SNE*, Journal of Machine Learning Research, vol. 9, pp. 2579–2605, 2008.

[20] J. MacQueen, *Some Methods for Classification and Analysis of Multivariate Observations*, Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, vol. 1, pp. 281–297, 1967.

[21] N. X. Vinh, J. Epps, and J. Bailey, *Information Theoretic Measures for Clusterings Comparison: Variants, Properties, Normalization and Correction for Chance*, Journal of Machine Learning Research, vol. 11, pp. 2837–2854, 2010.

[22] L. Hubert and P. Arabie, *Comparing Partitions*, Journal of Classification, vol. 2, pp. 193–218, 1985.

[23] P. J. Rousseeuw, *Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis*, Journal of Computational and Applied Mathematics, vol. 20, pp. 53–65, 1987.

[24] D. L. Davies and D. W. Bouldin, *A Cluster Separation Measure*, IEEE Transactions on Pattern Analysis and Machine Intelligence, vol. PAMI-1, no. 2, pp. 224–227, 1979.

[25] T. Caliński and J. Harabasz, *A Dendrite Method for Cluster Analysis*, Communications in Statistics, vol. 3, no. 1, pp. 1–27, 1974.

[26] R. O. Duda, P. E. Hart, and D. G. Stork, *Pattern Classification*, 2nd ed., Wiley, 2001.

[27] P. C. Mahalanobis, *On the Generalized Distance in Statistics*, Proceedings of the National Institute of Sciences of India, vol. 2, no. 1, pp. 49–55, 1936.

[28] T. M. Cover and P. E. Hart, *Nearest Neighbor Pattern Classification*, IEEE Transactions on Information Theory, vol. 13, no. 1, pp. 21–27, 1967.

[29] D. R. Cox, *The Regression Analysis of Binary Sequences*, Journal of the Royal Statistical Society: Series B, vol. 20, no. 2, pp. 215–232, 1958.

[30] L. Breiman, *Random Forests*, Machine Learning, vol. 45, pp. 5–32, 2001.

[31] P. Langley, W. Iba, and K. Thompson, *An Analysis of Bayesian Classifiers*, Proceedings of the Tenth National Conference on Artificial Intelligence, pp. 223–228, 1992.

[32] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*, Proceedings of the Second International Conference on Knowledge Discovery and Data Mining, pp. 226–231, 1996.

Appendice A

Dettagli implementativi e visualizzazioni aggiuntive

A.1 Visualizzazioni complete della rimozione selettiva dal training set

In questa sezione sono riportate le visualizzazioni complete del training set prima e dopo la rimozione selettiva dei punti individuati tramite DBSCAN. A differenza delle figure inserite nel Capitolo 6, qui viene mostrato anche il confronto con la distribuzione iniziale dei campioni di addestramento.

Nelle visualizzazioni complete, i punti rimossi non vengono eliminati completamente dalla rappresentazione, ma sono mostrati come marcatori grigi a forma di X. Questa scelta permette di evidenziare visivamente quali campioni sono stati rimossi in ciascun esperimento e in quali regioni dello spazio degli embedding essi erano collocati.

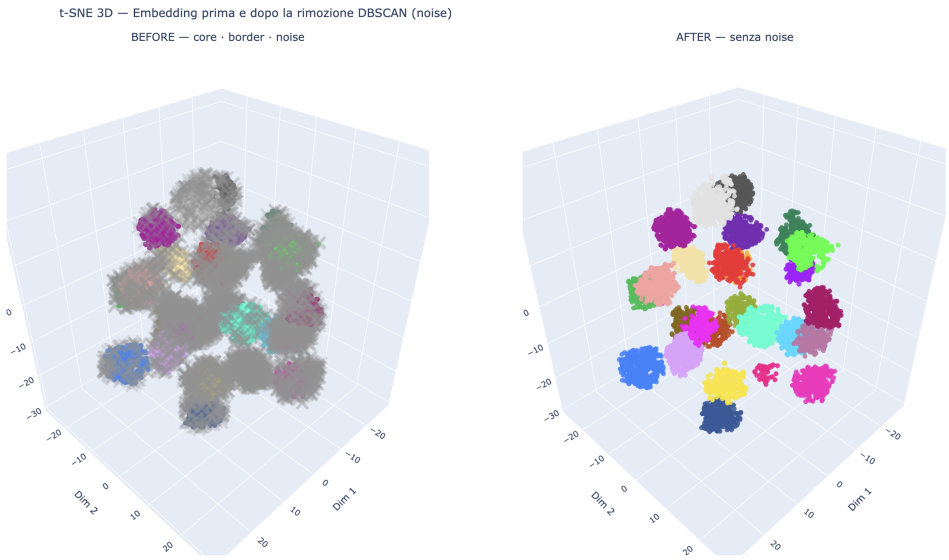


Figura A.1: Confronto del training set prima e dopo la rimozione dei punti noise.

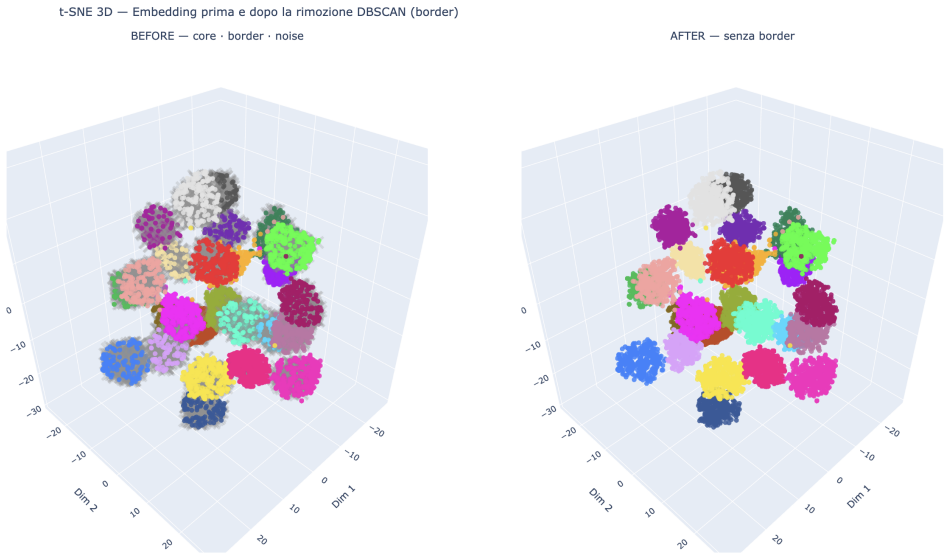


Figura A.2: Confronto del training set prima e dopo la rimozione dei punti border.

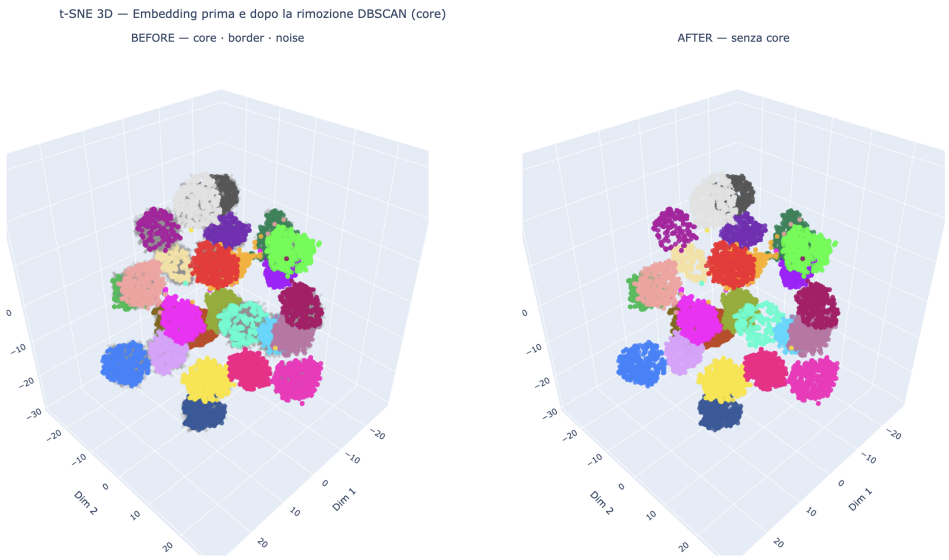


Figura A.3: Confronto del training set prima e dopo la rimozione dei punti core.

Appendice B

Risultati sperimentali aggiuntivi

B.1 Top 5 di confusione nelle diverse configurazioni

In questa sezione sono riportate le top 5 complete ottenute dagli esperimenti aggiuntivi descritti nel Capitolo 5. A differenza della configurazione iniziale riportata nel corpo principale del capitolo, basata su una suddivisione 80/20 del dataset, le tabelle seguenti fanno riferimento alla suddivisione 80/10/10.

Le classifiche derivano dalle matrici di confusione dei tre classificatori utilizzati e indicano, per ciascuna configurazione, i generatori maggiormente coinvolti nelle confusioni.

I valori di MeanConfusion sono riportati arrotondati alla quarta cifra decimale, così da rendere le tabelle più leggibili. Nella tabella riassuntiva delle occorrenze vengono considerate soltanto le presenze con MeanConfusion maggiore di zero, in modo da non attribuire rilevanza a generatori presenti nella top 5 con valore nullo.

Generatore	**Occorrenze con MeanConfusion** > 0
LaMa	18
MAT	17
Denoising_Diffusion_GAN	6
StyleGAN3	6
GANformer	5
StyleGAN1	5
Cycle_GAN	4
Palette	4
Generative_Inpainting	3
REAL	2
SFHQ	2
Stable_Diffusion	2
CIPS	1
ProGAN	1
Taming_Transformer	1

Tabella B.1: Generatori più ricorrenti nelle 21 top 5 delle confusioni, considerando solo valori di MeanConfusion maggiori di zero.

Dalla tabella si osserva che LaMa e MAT sono i generatori più ricorrenti, comparendo rispettivamente in 18 e 17 top 5 su 21 con valori di MeanConfusion maggiori di zero. Questo risultato suggerisce che tali generatori sono frequentemente coinvolti nelle confusioni dei classificatori anche nella configurazione con suddivisione 80/10/10.

In particolare, Denoising_Diffusion_GAN e StyleGAN3 compaiono 6 volte, mentre GANformer e StyleGAN1 compaiono 5 volte. Questo indica che esistono ulteriori confusioni, ma meno stabili rispetto a quelle osservate per LaMa e MAT.

Logistic Regression

Configurazione	Pos.	Generatore	MeanConfusion
None – esec. 1	1	GANformer	0.0005
	2	LaMa	0.0005
	3	MAT	0.0005
	4	CIPS	0.0000
	5	BigGAN	0.0000
None – esec. 2	1	Cycle_GAN	0.0005
	2	LaMa	0.0005
	3	MAT	0.0005
	4	StyleGAN1	0.0005
	5	BigGAN	0.0000
None – esec. 3	1	MAT	0.0015
	2	Cycle_GAN	0.0005
	3	SFHQ	0.0005
	4	StyleGAN1	0.0005
	5	LaMa	0.0005
None – esec. 4	1	Denoising_Diffusion_GAN	0.0005
	2	LaMa	0.0005
	3	MAT	0.0005
	4	StyleGAN1	0.0005
	5	BigGAN	0.0000
Random state 42	1	LaMa	0.0015
	2	Generative_Inpainting	0.0005
	3	Stable_Diffusion	0.0005
	4	MAT	0.0005
	5	StyleGAN3	0.0005
Random state 123	1	LaMa	0.0015
	2	MAT	0.0010
	3	GANformer	0.0005
	4	StyleGAN1	0.0005
	5	BigGAN	0.0000
Random state 999	1	Denoising_Diffusion_GAN	0.0005
	2	LaMa	0.0005
	3	StyleGAN1	0.0005
	4	StyleGAN3	0.0005
	5	BigGAN	0.0000

Tabella B.2: Top 5 dei generatori più coinvolti nelle confusioni della Logistic Regression.

Random Forest

Configurazione	Pos.	Generatore	MeanConfusion
None – esec. 1	1	MAT	0.0010
	2	REAL	0.0005
	3	LaMa	0.0005
	4	Taming_Transformer	0.0005
	5	CIPS	0.0000
None – esec. 2	1	MAT	0.0015
	2	Denoising_Diffusion_GAN	0.0010
	3	Cycle_GAN	0.0005
	4	REAL	0.0005
	5	Palette	0.0005
None – esec. 3	1	MAT	0.0005
	2	REAL	0.0000
	3	CIPS	0.0000
	4	Cycle_GAN	0.0000
	5	DDPM	0.0000
None – esec. 4	1	LaMa	0.0015
	2	Palette	0.0005
	3	SFHQ	0.0005
	4	CIPS	0.0000
	5	DDPM	0.0000
Random state 42	1	Palette	0.0010
	2	LaMa	0.0005
	3	StyleGAN3	0.0005
	4	ProGAN	0.0005
	5	DDPM	0.0000
Random state 123	1	LaMa	0.0010
	2	GANformer	0.0005
	3	MAT	0.0005
	4	CIPS	0.0000
	5	BigGAN	0.0000
Random state 999	1	Denoising_Diffusion_GAN	0.0005
	2	MAT	0.0005
	3	StyleGAN3	0.0005
	4	CIPS	0.0000
	5	BigGAN	0.0000

Tabella B.3: Top 5 dei generatori più coinvolti nelle confusioni della Random Forest.

Naive Bayes

Configurazione	Pos.	Generatore	MeanConfusion
None – esec. 1	1	LaMa	0.0015
	2	Palette	0.0010
	3	Cycle_GAN	0.0005
	4	MAT	0.0005
	5	CIPS	0.0005
None – esec. 2	1	MAT	0.0010
	2	LaMa	0.0005
	3	CIPS	0.0000
	4	Cycle_GAN	0.0000
	5	DDPM	0.0000
None – esec. 3	1	LaMa	0.0015
	2	REAL	0.0000
	3	CIPS	0.0000
	4	Cycle_GAN	0.0000
	5	DDPM	0.0000
None – esec. 4	1	LaMa	0.0010
	2	GANformer	0.0005
	3	Generative_Inpainting	0.0005
	4	MAT	0.0005
	5	Denoising_Diffusion_GAN	0.0005
Random state 42	1	LaMa	0.0015
	2	MAT	0.0010
	3	Stable_Diffusion	0.0005
	4	Generative_Inpainting	0.0005
	5	StyleGAN3	0.0005
Random state 123	1	LaMa	0.0020
	2	MAT	0.0015
	3	GANformer	0.0005
	4	CIPS	0.0000
	5	BigGAN	0.0000
Random state 999	1	LaMa	0.0020
	2	StyleGAN3	0.0010
	3	Denoising_Diffusion_GAN	0.0005
	4	MAT	0.0005
	5	BigGAN	0.0000

Tabella B.4: Top 5 dei generatori più coinvolti nelle confusioni del Naive Bayes.

B.2 Top 5 dopo la rimozione selettiva dei punti

In questa sezione sono riportate le top 5 complete ottenute dagli esperimenti descritti nel Capitolo 6. Le tabelle confrontano, per ciascun classificatore, i risultati ottenuti addestrando il modello sul training set completo con quelli ottenuti dopo la rimozione, sempre dal training set, dei punti noise, border e core individuati tramite DBSCAN. Gli insiemi di validation e test rimangono invariati in tutte le configurazioni.

Logistic Regression

Configurazione	**Pos.**	**Generatore**	**MeanConfusion**
Completo	1	LaMa	0.0015
	2	Generative_Inpainting	0.0005
	3	Stable_Diffusion	0.0005
	4	MAT	0.0005
	5	StyleGAN3	0.0005
Senza noise	1	LaMa	0.0035
	2	MAT	0.0020
	3	VQ_Diffusion	0.0005
	4	StyleGAN3	0.0005
	5	DDPM	0.0000
Senza border	1	LaMa	0.0010
	2	Generative_Inpainting	0.0005
	3	Stable_Diffusion	0.0005
	4	MAT	0.0005
	5	StyleGAN3	0.0005
Senza core	1	LaMa	0.0010
	2	Generative_Inpainting	0.0005
	3	Stable_Diffusion	0.0005
	4	MAT	0.0005
	5	StyleGAN3	0.0005

Tabella B.5: Top 5 dei generatori più coinvolti nelle confusioni della Logistic Regression dopo la rimozione selettiva di campioni dal training set.

Random Forest

Configurazione	Pos.	Generatore	MeanConfusion
Completo	1	Palette	0.0010
	2	LaMa	0.0005
	3	StyleGAN3	0.0005
	4	ProGAN	0.0005
	5	DDPM	0.0000
Senza noise	1	MAT	0.0025
	2	LaMa	0.0025
	3	StyleGAN1	0.0010
	4	StyleGAN3	0.0005
	5	CIPS	0.0005
Senza border	1	LaMa	0.0005
	2	Generative_Inpainting	0.0005
	3	MAT	0.0005
	4	Palette	0.0005
	5	StyleGAN3	0.0005
Senza core	1	LaMa	0.0010
	2	Generative_Inpainting	0.0005
	3	MAT	0.0005
	4	Palette	0.0005
	5	Stable_Diffusion	0.0005

Tabella B.6: Top 5 dei generatori più coinvolti nelle confusioni della Random Forest dopo la rimozione selettiva di campioni dal training set.

Naive Bayes

Configurazione	Pos.	Generatore	MeanConfusion
Completo	1	LaMa	0.0015
	2	MAT	0.0010
	3	Stable_Diffusion	0.0005
	4	Generative_Inpainting	0.0005
	5	StyleGAN3	0.0005
Senza noise	1	LaMa	0.0030
	2	MAT	0.0015
	3	StyleGAN3	0.0005
	4	StyleGAN2	0.0005
	5	DDPM	0.0000
Senza border	1	MAT	0.0010
	2	LaMa	0.0010
	3	Stable_Diffusion	0.0005
	4	Generative_Inpainting	0.0005
	5	StyleGAN3	0.0005
Senza core	1	LaMa	0.0015
	2	MAT	0.0015
	3	Generative_Inpainting	0.0005
	4	CIPS	0.0000
	5	DDPM	0.0000

Tabella B.7: Top 5 dei generatori più coinvolti nelle confusioni del Naive Bayes dopo la rimozione selettiva di campioni dal training set.

Ringraziamenti

A Mamma Rosalba e Papà Antonio

Grazie per avermi sempre supportato, ma soprattutto sopportato. Anche se, a dirla tutta, questo carattere da qualcuno devo pur averlo ereditato, no?

Grazie per essermi stati accanto durante tutto questo percorso, nei momenti più semplici e in quelli un po' meno semplici. Questo traguardo è anche vostro e voglio dedicarlo a voi.

A Nonna Assunta e Nonno Antonio

Grazie per avermi sempre incoraggiato e per aver sempre creduto in me.

Grazie Nonna Assunta, per avermi chiamato ogni sera prima di ogni esame per dirmi che sarebbe andato tutto bene. Anche quando uscivo dall'aula e ti chiamavo convinto di essere stato bocciato, tu in fondo non ci credevi mai. E, bisogna ammetterlo, molto spesso avevi ragione tu.

Grazie Nonno Antonio, per avermi sempre chiamato "Dottore", da quando ero così piccolo che non sapevo nemmeno leggere e scrivere. Anche se, a dire il vero, non sono sicuro di saperlo fare benissimo nemmeno oggi. Dopo tanti anni, però, finalmente puoi chiamarmi Dottore per davvero.

Questo traguardo è soprattutto per voi. Grazie.

A Zia Meri e Zio Antonio

Grazie Zia, per aver sperato a ogni esame nel fatidico 27. A dire il vero non è che ne abbia presi poi così tanti, ma visto che il mio percorso di studi non finisce qui, avrai ancora parecchie occasioni per sperarci. D'altronde, la speranza è l'ultima a morire.

Grazie Zio, per l'affetto e per esserci sempre stato. Adesso, però, c'è una questione molto più importante da chiarire: siamo ufficialmente in due ad essere Dottori. Di conseguenza mi aspetto che, la domenica quando mangiamo tutti insieme, saremo i primi ad essere serviti. E possibilmente con una porzione abbondante: direi che ce la siamo meritata.

Grazie ad entrambi.

Ai miei fratelli, Giulio e Gabriele

Grazie Giulio. Colgo questa occasione per ringraziarti per tutto. Se oggi sono quello che sono, nel bene e nel male, una parte della colpa è sicuramente tua. Se ripenso alla mia infanzia, una buona parte dei ricordi più belli è legata a tutti gli anni che abbiamo passato insieme, praticamente sempre uno accanto all'altro, a giocare, ridere e inventarci qualcosa da fare.

Probabilmente, tra tutte quelle ore passate insieme a giocare, sei riuscito anche a trasmettermi quella poca voglia di andare a lavorare che ancora oggi mi porto dietro.

E infine, il tuo famoso "regalo" è stato sicuramente una motivazione in più per arrivare fino a qui. Dopo tutti questi anni di attesa, non vedo l'ora di riceverlo.

Grazie.

Grazie Gabriele, conosciuto anche come Orsacchiotto. Ammetto che, pensando a cosa scrivere su di te, inizialmente mi sono venute in mente soprattutto cose negative, ma farò uno sforzo e proverò a trovarne qualcuna bella.

Non hai contribuito in maniera particolarmente diretta a questa laurea. Anzi, quelle poche volte in cui rimanevo a Fisciano per studiare, il tuo modo di incoraggiarmi era generalmente: "Torna a casa e stai con me!".

Però sono sicuro che non dimenticherò mai tutto il tempo passato insieme: i litigi, le bisticciate, le volte in cui ci siamo anche picchiati e, due minuti dopo, eravamo di nuovo insieme come se non fosse successo nulla; tutte le ore passate a giocare, parlare e soprattutto ridere.

Alla fine, anche se probabilmente non te lo dirò spesso, sono contento di averti avuto accanto durante tutti questi anni. Tra tutti i fratelli che potevano capitarmi, alla fine non mi è andata nemmeno così male.

Grazie, Orsacchiotto.